

Júlia Almeida Leite
Maria Eduarda Mariano Coelho

**Sistema Inteligente de Tradução de Libras
Utilizando Visão Computacional e
Processamento de Linguagem Natural**

São Paulo
2026

Júlia Almeida Leite
Maria Eduarda Mariano Coelho

Sistema Inteligente de Tradução de Libras Utilizando Visão Computacional e Processamento de Linguagem Natural

Proposta de Trabalho de Conclusão de Curso
apresentado ao SENAC Santo Amaro como
requisito parcial para aprovação na disciplina
de TCC1 do curso de Bacharelado em Ciência
da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Curso de Bacharelado em Ciência da Computação

Orientador: Prof. Thyago Conchado Quintas

São Paulo
2026

Resumo

Este documento apresenta a proposta inicial do Trabalho de Conclusão de Curso (TCC1) desenvolvido no SENAC Santo Amaro. O objetivo deste trabalho é [descrever brevemente o objetivo principal do TCC]. A justificativa para este estudo baseia-se em [descrever brevemente a justificativa]. A revisão bibliográfica abrange [mencionar os principais tópicos]. Como solução proposta, pretende-se [descrever brevemente a solução]. Este trabalho está organizado em três capítulos que apresentam a introdução ao tema, a revisão bibliográfica que fundamenta a pesquisa, o desenvolvimento com a solução proposta e o cronograma de trabalho, seguidos das referências bibliográficas.

Palavras-chave: palavra1. palavra2. palavra3. palavra4. palavra5.

Sumário

1	INTRODUÇÃO	5
1.1	Contexto	5
1.2	Justificativa	6
1.3	Objetivo	7
1.3.1	Objetivo principal	7
1.3.2	Objetivos secundários	7
2	REVISÃO BIBLIOGRÁFICA	8
2.1	Referencial teórico	8
2.2	Metodologia da pesquisa bibliográfica	8
2.3	Fundamentos	9
2.3.1	Linguagem da Língua Brasileira de Sinais (Libras)	9
2.3.2	Bases de Dados (Datasets)	11
2.3.3	Pré-processamento de Dados	11
2.3.4	Visão Computacional	12
2.3.5	Landmarks (Pontos-chave)	13
2.3.6	MediaPipe	14
2.3.7	Deep Learning	15
2.3.8	Redes Neurais Convolucionais (CNN)	16
2.3.9	Redes de Memória de Longo Prazo (LSTM)	18
2.3.10	Custo Computacional e Peso dos Modelos	19
2.3.11	Reconhecimento de Gestos (Gesture Recognition)	20
2.3.12	Processamento de Linguagem Natural (NLP)	20
2.3.13	Árvores de Dependência Sintática	22
2.3.14	Integração Visão Computacional + NLP	23
2.3.15	Acurácia e Matriz de Confusão	24
2.3.16	Métrica BLEU	24
2.3.17	Latência e Tempo de Resposta	25
2.4	Trabalhos relacionados	25
2.4.1	Trabalho 1: Sign Language Translator System Using Computer Vision and LSTM Neural Networks	25
2.4.2	Trabalho 2: Interpretação de gestos de Libras usando K-Means e Random Forest	26
2.4.3	Trabalho 3: Detection and Interpretation of Indian Sign Language Using LSTM Networks	27

3	DESENVOLVIMENTO	28
3.1	Solução proposta	29
3.1.1	Visão geral da solução	29
3.1.2	Arquitetura	31
3.1.3	Tecnologias e ferramentas	31
3.1.4	Funcionalidades principais	32
3.1.5	Metodologia de desenvolvimento	32
3.1.6	Critérios de validação	33
3.2	Cronograma de trabalho	33
	REFERÊNCIAS	35

1 Introdução

A comunicação é extremamente importante para promover a inclusão social. No entanto, muitas pessoas surdas que utilizam a Língua Brasileira de Sinais (Libras) encontram barreiras na interação com aqueles que não conhecem essa linguagem. Essa limitação afeta diretamente o acesso a serviços, educação e oportunidades do dia a dia.

O desafio da comunicação reside no fato de que a Libras e a Língua Portuguesa possuem modalidades distintas, sendo esta oral-auditiva e linear, e aquela visual-espacial e simultânea, o que resulta em gramáticas e estruturas sintáticas completamente divergentes (([OLIZAROSKI; MOLIN, 2024](#))).

Com a evolução das tecnologias em inteligência artificial, principalmente em visão computacional e processamento de linguagem natural, surgem novas maneiras de diminuir essas barreiras. Sistemas que conseguem reconhecer gestos e convertê-los automaticamente em texto podem ser uma solução bastante promissora para facilitar a interação entre surdos e ouvintes.

Nesse cenário, o Processamento de Linguagem Natural (PLN) desempenha um papel fundamental ao atuar como uma camada de conversão inteligente. Sua função é interpretar os sinais isolados identificados pela visão computacional e reorganizá-los semanticamente e sintaticamente, realizando os ajustes de concordância e ordem frasal necessários para transformar a estrutura própria da Libras em frases coerentes e gramaticalmente corretas na língua portuguesa.

É importante ressaltar que, devido à amplitude lexical da Libras e à natureza experimental deste estudo, o sistema proposto não visa uma tradução universal imediata. A pesquisa delimita-se ao reconhecimento de um conjunto inicial de vocabulários voltados a contextos específicos, para garantir o rigor técnico na integração entre a visão computacional e o PLN, estabelecendo um modelo de referência que possa, em etapas posteriores, ser expandido para um léxico mais abrangente.

Diante disso, nosso trabalho propõe desenvolver um sistema de tradução de Libras, aplicando técnicas de visão computacional para reconhecer os sinais e processamento de linguagem natural para gerar frases em português. O objetivo é contribuir para a inclusão social com uma solução acessível, eficiente e aplicável em diversos contextos.

1.1 Contexto

A comunicação é necessária para a integração social e o exercício da cidadania. Contudo, para a comunidade surda no Brasil, essa interação muitas vezes é limitada por barreiras linguísticas significativas. Conforme dados do ([IBGE, 2019](#)), o Brasil conta com mais de

10 milhões de pessoas com algum nível de deficiência auditiva, sendo cerca de 2,3 milhões completamente surdas.

Embora a Língua Brasileira de Sinais (Libras) seja o principal meio de comunicação desta comunidade, estima-se que até 2025, menos de 0,5% da população (cerca de 1 milhão de pessoas) entenderão ou dominarão a língua. Essa lacuna na comunicação gera uma dependência constante de intérpretes, que são poucos e frequentemente inacessíveis em situações cotidianas.

1.2 Justificativa

A comunicação é fundamental para a inclusão social e para a participação das pessoas na sociedade. No Brasil, embora a Língua Brasileira de Sinais (Libras) seja reconhecida oficialmente, ainda existem dificuldades na comunicação entre pessoas surdas e ouvintes. Um dos principais motivos é o número reduzido de pessoas que conhecem a língua, o que acaba limitando interações no dia a dia. Diante disso, torna-se importante pensar em alternativas que utilizem tecnologia para facilitar essa comunicação e tornar o acesso mais inclusivo.

Do ponto de vista acadêmico, este trabalho se insere na área de Ciência da Computação ao combinar técnicas de visão computacional e processamento de linguagem natural em uma mesma solução. Trata-se de um problema que não é simples, pois envolve desde o reconhecimento de movimentos e gestos até a construção de frases compreensíveis em português. Além disso, lidar com dados visuais em sequência e interpretar corretamente os sinais são desafios relevantes, o que torna a proposta interessante como estudo e desenvolvimento na área de inteligência artificial aplicada.

Em relação à prática, a proposta pode trazer benefícios concretos, principalmente para a comunidade surda. Um sistema capaz de traduzir Libras automaticamente pode ajudar a diminuir a dependência de intérpretes em situações cotidianas, como atendimentos, ambientes educacionais ou interações básicas. Com isso, há um ganho em autonomia e acessibilidade, além de ampliar as possibilidades de comunicação em diferentes contextos.

Apesar de já existirem pesquisas nessa área, ainda há aspectos que podem ser melhor explorados. Muitos trabalhos focam no reconhecimento de sinais isolados, sem considerar de forma mais ampla o contexto da comunicação. Outros utilizam bancos de dados específicos, relacionados à representação das variações da Libras. Além disso, ainda são limitados os estudos que integram todo o processo, desde a identificação dos gestos até a formação de frases com sentido em português.

Portanto, este trabalho busca avançar nesse quesito ao propor uma solução mais integrada, que não se limite apenas ao reconhecimento individual de sinais, mas que também considere a construção da linguagem. A intenção é contribuir tanto para a área acadêmica quanto para a sociedade, explorando uma aplicação prática da inteligência

artificial voltada à acessibilidade.

1.3 Objetivo

Os objetivos deste trabalho estão voltados para o desenvolvimento de uma solução capaz de auxiliar na comunicação entre pessoas surdas e ouvintes por meio da tradução automática de Libras. Para isso, define-se um objetivo principal que orienta a proposta geral do sistema, enquanto os objetivos secundários detalham as etapas necessárias para sua construção, incluindo desde o tratamento dos dados até a implementação e avaliação da solução.

1.3.1 Objetivo principal

Implementar um sistema computacional capaz de reconhecer gestos da Língua Brasileira de Sinais (Libras) por meio de visão computacional e traduzi-los em texto, utilizando técnicas de processamento de linguagem natural.

1.3.2 Objetivos secundários

1. Selecionar, estruturar e tratar datasets de Libras;
2. Desenvolver um modelo de visão computacional para detecção e reconhecimento dos sinais manuais;
3. Implementar um módulo de processamento de linguagem natural para lidar com um conjunto definido de palavras e formar frases simples em português;
4. Integrar os módulos em um sistema funcional de tradução com processamento em tempo real;
5. Avaliar o desempenho do sistema utilizando diferentes métricas.

2 Revisão Bibliográfica

Neste capítulo, são apresentados os conceitos fundamentais necessários para o entendimento do projeto. Inicialmente, são abordadas as diferenças estruturais entre a Língua Brasileira de Sinais (Libras) e a Língua Portuguesa. Em seguida, são apresentados os fundamentos de visão computacional aplicados ao reconhecimento de gestos e o uso de redes neurais. Por fim, são discutidos conceitos de processamento de linguagem natural, que servirão como base para a construção de frases em português a partir dos sinais identificados.

2.1 Referencial teórico

A tradução automática de Libras envolve desafios complexos, pois essa linguagem possui estrutura gramatical própria, distinta do português, além de depender de expressões corporais e movimentos tridimensionais. Tradicionalmente, estudos nessa área utilizam técnicas de visão computacional para capturar movimentos e reconhecer padrões.

Com o avanço do aprendizado profundo, modelos baseados em redes neurais convolucionais (CNNs) têm sido amplamente utilizados para reconhecimento de imagens e vídeos, enquanto redes recorrentes, como LSTM e GRU, são aplicadas para lidar com sequências temporais de gestos.

Além disso, técnicas de processamento de linguagem natural permitem transformar sequências de sinais em frases coerentes, considerando aspectos sintáticos e semânticos da língua portuguesa.

Apesar dos avanços, ainda existem desafios relacionados à disponibilidade de dados e integração eficiente entre reconhecimento visual e geração de linguagem. Dessa forma, este trabalho propõe uma abordagem integrada, buscando desenvolver um sistema funcional e aplicável ao contexto real.

2.2 Metodologia da pesquisa bibliográfica

A pesquisa bibliográfica foi realizada nas bases Google Scholar e IEEE Xplore, utilizando as strings de busca "Libras"AND "Deep Learning"AND "Visão Computacional", "Reconhecimento de sinais"AND "Libras"AND ("CNN"OR "LSTM") e "Língua Brasileira de Sinais"AND "Acessibilidade"AND "Redes Neurais". Foram selecionados artigos publicados entre 2021 e 2026, em português e inglês, que abordassem diretamente o reconhecimento automático de sinais, técnicas de visão computacional aplicadas à Libras e métodos de processamento de linguagem natural voltados à tradução de linguagem de sinais.

2.3 Fundamentos

A escolha das arquiteturas utilizadas neste trabalho está diretamente relacionada às diferenças estruturais entre a Língua Brasileira de Sinais (Libras) e a Língua Portuguesa, discutidas na revisão bibliográfica. Enquanto o português apresenta uma organização linear e sequencial, a Libras caracteriza-se por uma estrutura visual-espacial, na qual informações são transmitidas simultaneamente por meio de configurações de mão, movimentos e expressões corporais.

Essa distinção impõe desafios específicos ao processo de tradução automática, exigindo o uso de técnicas capazes de lidar tanto com a análise espacial dos sinais quanto com sua evolução temporal e posterior reorganização linguística. Nesse contexto, são empregadas Redes Neurais Convolucionais para captura de padrões visuais, Redes LSTM para modelagem de sequências de movimento e técnicas de Processamento de Linguagem Natural para adaptação da estrutura gramatical ao português.

2.3.1 Linguagem da Língua Brasileira de Sinais (Libras)

A Língua Brasileira de Sinais (Libras) é uma língua natural, completa e autônoma, utilizada pela comunidade surda no Brasil, reconhecida pela Lei nº 10.436/2002 e regulamentada pelo Decreto nº 5.626/2005 como meio legal de comunicação e expressão. Possui estrutura gramatical própria, independente da Língua Portuguesa, e está inserida em um contexto cultural e linguístico específico da comunidade surda.

Do ponto de vista linguístico, a Libras pertence à modalidade visual-espacial, em contraste com a modalidade oral-auditiva do português. Essa diferença implica mudanças importantes na forma como a informação é organizada: enquanto a língua portuguesa apresenta uma estrutura linear, em que os elementos aparecem em sequência, a Libras permite expressar diferentes informações ao mesmo tempo, por meio da combinação de sinais, movimentos e expressões faciais. Estudos mostram que as línguas de sinais possuem as mesmas propriedades das línguas naturais, como criatividade, organização por regras e capacidade de expressar qualquer tipo de conteúdo ([QUADROS; KARNOPP, 2004](#)).



Figura 1 – Parâmetros de formação do sinal na Libras.

Fonte: Felipe (2013).

No nível fonológico, os sinais são formados por parâmetros básicos, conforme detalhado na Figura 1: a configuração de mão (CM), o movimento (M), a locação (L), a orientação (Or) e as expressões não manuais (ENM). A combinação desses elementos forma os sinais, e mudanças em qualquer um desses parâmetros podem alterar o significado.

Do ponto de vista morfológico, a Libras apresenta uma estrutura diferente da língua portuguesa. Em vez de adicionar partes de forma sequencial (como prefixos e sufixos), os elementos do sinal são combinados ao mesmo tempo. Por exemplo, informações como número, negação e até mesmo o objeto da ação podem ser incorporadas diretamente ao sinal. Além disso, a relação entre quem realiza e quem recebe a ação pode ser indicada pela direção do movimento no espaço, utilizando pontos de referência criados durante a comunicação ((QUADROS; KARNOPP, 2004)).

No nível sintático, a língua portuguesa segue predominantemente a ordem Sujeito-Verbo-Objeto (SVO). Já a Libras apresenta maior flexibilidade, sendo possíveis diferentes organizações, como SVO, SOV, OSV e VOS, dependendo do contexto. Isso ocorre porque a língua utiliza o espaço para indicar relações entre os elementos da frase, reduzindo a necessidade de uma ordem fixa.

Essas diferenças impactam diretamente o processo de tradução automática. Elementos comuns no português, como artigos e preposições, nem sempre aparecem de forma explícita na Libras, pois muitas dessas relações são expressas pelo uso do espaço e pelo contexto. Por isso, sistemas computacionais precisam não apenas reconhecer os sinais, mas também reorganizar as informações e incluir elementos necessários para gerar frases corretas em português.

2.3.2 Bases de Dados (Datasets)

No desenvolvimento de modelos de Aprendizado Profundo, o dataset (base de dados) constitui o pilar fundamental para o treinamento e a validação do sistema. Segundo [Schmidhuber \(2014\)](#), a eficácia de arquiteturas complexas como CNNs e LSTMs depende diretamente da disponibilidade de grandes volumes de dados rotulados, que permitem ao modelo aprender representações estatísticas precisas e generalizáveis.

No contexto do reconhecimento de Libras, os datasets apresentam desafios únicos devido à natureza multimodal da língua. Uma base de dados robusta para este fim deve conter não apenas imagens isoladas, mas sequências de vídeo que capturem a dinâmica dos sinais. De acordo com [Silva \(2017\)](#), a diversidade dos dados é crucial para mitigar problemas de overfitting, garantindo que o sistema seja capaz de reconhecer gestos realizados por diferentes usuários, com variações em:

- Antropometria: Diferenças no tamanho, cor e formato das mãos dos sinalizadores;
- Condições Ambientais: Variações de iluminação e fundos de imagem (backgrounds) complexos, que testam a capacidade de segmentação do modelo;
- Execução do Sinal: Diferenças na velocidade, amplitude e fluidez do movimento, que impactam diretamente a análise temporal das redes LSTM.

Além disso, a estruturação do dataset deve prever a divisão entre conjuntos de treinamento, validação e teste. Conforme explicam [Goodfellow, Bengio e Courville \(2016\)](#), essa separação é o que permite avaliar a capacidade de generalização do algoritmo frente a dados nunca vistos, assegurando que o tradutor de Libras funcione corretamente em cenários do mundo real e não apenas em ambientes controlados de laboratório.

2.3.3 Pré-processamento de Dados

Antes da aplicação dos modelos de aprendizado profundo, é necessária uma etapa de pré-processamento dos dados visuais, com o objetivo de melhorar a qualidade das informações fornecidas ao sistema e aumentar a precisão do reconhecimento dos sinais.

O pré-processamento envolve técnicas de tratamento de imagem, como redimensionamento dos frames, normalização dos valores de pixel e remoção de ruídos. Além disso, podem ser aplicados filtros para suavização da imagem e ajuste de contraste, reduzindo interferências causadas por variações de iluminação e fundo. Segundo [Szeliski \(2010\)](#), essas etapas são fundamentais para garantir que os algoritmos de visão computacional consigam extrair características relevantes de forma eficiente.

Outro aspecto relevante é a padronização dos dados de entrada, garantindo que todas as imagens ou sequências possuam dimensões e formatos consistentes. Essa uniformidade é

essencial para funcionamento correto das redes neurais, especialmente em modelos baseados em CNN e LSTM.

Também é importante o balanceamento de classes. Em datasets de reconhecimento de sinais, é comum que determinadas classes possuam um número de amostras significativamente maior do que outras. Quando treinado sobre dados desbalanceados, o modelo tende a favorecer as classes com maior quantidade, comprometendo o desempenho nas classes menor quantidade (CHAWLA et al., 2002).

Os três datasets adotados neste projeto apresentam diversidade de dados a esse respeito: o MINDS-Libras conta com distribuição controlada, são 6 pessoas realizando 5 repetições de cada um dos 20 sinais, resultando em classes uniformes (REZENDE, 2021); o V-Libras possui estrutura igualmente regular, com exatamente 3 gravações por sinal para cada um dos 1.364 termos (RODRIGUES, 2021); já o dataset Libras Brazilian Sign Language, composto por imagens estáticas do alfabeto manual, apresenta variação relevante no número de amostras entre as classes, característica comum em datasets tratados a partir de fontes variadas (PAS, 2020).

Além disso, a integração dos três pode ampliar desequilíbrios, visto que as interseções de vocabulário entre eles são parciais e as quantidades de amostras por sinal diferem. Para mitigar esse problema, serão adotadas estratégias complementares: *data augmentation* (espelhamento, rotações e variações de velocidade dos vídeos) para aumentar as classes minoritárias; SMOTE (*Synthetic Minority Over-sampling Technique*), aplicado sobre os vetores de *landmarks* extraídos pelo MediaPipe, e não diretamente sobre pixels, gerando exemplos sintéticos por interpolação entre amostras próximas no espaço de características (CHAWLA et al., 2002); e ponderação de classes na função de perda durante o treinamento, penalizando mais os erros cometidos nas classes menos frequentes (GOODFELLOW; BENGIO; COURVILLE, 2016).

No contexto deste trabalho, o pré-processamento também inclui a preparação das sequências de vídeo, organizando os frames de forma temporal para posterior análise pelo modelo LSTM.

2.3.4 Visão Computacional

A Visão Computacional é a ciência que permite que máquinas enxerguem e interpretem o meio à sua volta. Através da captura de imagens por câmeras e sensores, o sistema extrai informações significativas que permitem reconhecer e manipular objetos (MILANO; HONORATO, 2014).

Essa tecnologia busca capacitar computadores a compreender o mundo visual de forma similar aos humanos. Segundo a Dave Bergmann (2025), enquanto a visão humana é intuitiva, as máquinas dependem de algoritmos para converter pixels e dados brutos em conceitos estruturados e compreensíveis.

No desenvolvimento deste projeto, a aplicação da visão computacional concentra-se prioritariamente na detecção de mãos. De acordo com [Neves, Neto e Gonzaga \(2012\)](#), essa etapa é crucial para localizar e isolar os membros superiores do restante do cenário, garantindo o foco nos sinais.

Outra aplicação fundamental é o reconhecimento de gestos, técnica que visa identificar movimentos e posições corporais a partir de dados visuais. Conforme explicam [Pinho, Tavares e Correia \(2004\)](#), essa análise é o que permite distinguir as diferentes configurações de mão que compõem o léxico da Libras.

Para viabilizar essas aplicações, utilizam-se técnicas de processamento de imagem, que preparam os dados brutos para análise. Segundo [Milano e Honorato \(2014\)](#), procedimentos como filtragem e redução de ruído são fundamentais para que o sistema ignore informações irrelevantes do fundo da imagem.

Por fim, aplica-se a extração de características para identificar padrões relevantes, como o formato e a trajetória das mãos, permitindo que o sistema identifique pontos específicos, chamados de landmarks, essenciais para a classificação precisa do sinal.

2.3.5 Landmarks (Pontos-chave)

Os landmarks, ou pontos-chave, são coordenadas específicas extraídas de partes relevantes do corpo, como mãos, dedos e articulações, utilizadas para representar a geometria e o movimento dos sinais.

No reconhecimento de Libras, os landmarks desempenham um papel fundamental, pois permitem reduzir a complexidade dos dados visuais. Em vez de processar toda a imagem, o sistema passa a trabalhar com um conjunto estruturado de pontos que descrevem a posição e a movimentação das mãos ao longo do tempo.

Ferramentas como o Google MediaPipe possibilitam a detecção desses pontos em tempo real, fornecendo informações como coordenadas tridimensionais (x, y, z) das articulações. Conforme ilustrado na Figura 2, o sistema mapeia 21 pontos distintos, organizados em grupos que representam o pulso (ponto 0), o polegar (pontos 1-4) e os demais dedos — indicador (5-8), médio (9-12), anelar (13-16) e mínimo (17-20).




Figura 2 – Mapeamento de pontos de referência (*landmarks*) da mão pelo MediaPipe.

Fonte: Jung (2021).

De acordo com [Lugaresi et al. \(2019\)](#), essa abordagem torna o processamento mais eficiente e robusto, além de reduzir a influência de fatores externos, como iluminação e fundo da imagem.

Dessa forma, os landmarks atuam como uma representação compacta e informativa dos sinais, facilitando tanto o processamento pelas redes neurais quanto a generalização do modelo para diferentes usuários.

2.3.6 MediaPipe

O MediaPipe é um *framework* de código aberto desenvolvido pelo Google para a construção de pipelines de percepção multimodal em tempo real ([LUGARESI et al., 2019](#)). Ele fornece um conjunto de soluções pré-treinadas para tarefas como detecção de pose corporal, rastreamento de rosto e, de forma central para este trabalho, detecção e rastreamento de mãos (*MediaPipe Hands*).

A solução *MediaPipe Hands* opera em dois estágios sequenciais ([ZHANG et al., 2020](#)). No primeiro, um detector leve baseado em aprendizado profundo localiza a palma da mão na imagem completa, produzindo um *bounding box* delimitador. No segundo, um modelo de regressão de *landmarks* recebe o recorte da mão e estima as coordenadas tridimensionais (x, y, z) de 21 pontos-chave que representam as articulações dos dedos e o pulso, conforme ilustrado na Figura 3. As coordenadas x e y são normalizadas em relação às dimensões do *frame* (valores entre 0 e 1), enquanto z representa a profundidade relativa ao pulso,

permitindo inferir a orientação tridimensional da mão mesmo com uma câmera RGB comum (ZHANG et al., 2020).




Figura 3 – Esquema dos 21 *landmarks* detectados pelo MediaPipe Hands.

Fonte: Zhang et al. (2020).

Do ponto de vista técnico, o diferencial do MediaPipe em relação a abordagens baseadas em segmentação de pele ou subtração de fundo é que ele não depende de condições controladas de iluminação ou de fundo homogêneo para localizar a mão: o detector opera diretamente sobre a imagem bruta e é robusto a variações de cor e textura do ambiente (LUGARESI et al., 2019). Além disso, a arquitetura leve do *framework* permite processamento em tempo real, atingindo taxas superiores a 30 *frames* por segundo em hardware convencional, o que o torna adequado para aplicações de tradução ao vivo.

No contexto deste projeto, o MediaPipe Hands substitui o processamento direto sobre pixels das imagens de câmera. Em vez de alimentar os modelos CNN e LSTM com *frames* completos – o que elevaria o custo computacional e aumentaria a sensibilidade a ruídos visuais, o sistema extrai os 21 *landmarks* por mão (totalizando até 63 coordenadas por *frame* quando duas mãos estão presentes) e utiliza esses vetores compactos como representação de entrada. Essa escolha reduz drasticamente a dimensionalidade dos dados, acelera o treinamento e a inferência, e torna o sistema mais generalizável entre diferentes usuários, pois a representação baseada em articulações é invariante a variações de tom de pele e textura das mãos (LUGARESI et al., 2019).

2.3.7 Deep Learning

O Deep Learning, ou Aprendizado Profundo, é uma subárea do aprendizado de máquina que utiliza redes neurais artificiais com múltiplas camadas de processamento. Segundo a Dave Bergmann (2026), essa abordagem é inspirada na estrutura do cérebro humano, onde

cada camada de "neurônios" executa operações matemáticas para aprender representações cada vez mais abstratas dos dados.

Diferente dos métodos tradicionais, o aprendizado profundo permite que o sistema identifique características automaticamente, sem a necessidade de intervenção humana manual. Conforme explica a [Oracle \(2022\)](#), essa capacidade de autoajuste através de pesos e vieses é o que torna os modelos extremamente precisos para resolver problemas complexos.

Um dos principais motivos para a ampla adoção desta tecnologia é o seu desempenho superior em tarefas que envolvem visão computacional e processamento de texto. De acordo com [Schmidhuber \(2014\)](#), o aprendizado profundo revolucionou o reconhecimento de padrões ao permitir a análise de grandes volumes de dados não estruturados.

No contexto deste projeto, o uso do Deep Learning justifica-se pela necessidade de tratar informações visuais e sequenciais simultaneamente. Segundo [Goodfellow, Bengio e Courville \(2016\)](#), redes profundas são aproximadores universais capazes de mapear entradas complexas para saídas específicas, como a tradução de um gesto em texto.

A relação direta com as arquiteturas CNN e LSTM ocorre porque o aprendizado profundo fornece a base para camadas especializadas. Enquanto as Redes Neurais Convolucionais (CNN) focam na hierarquia espacial das imagens, as redes de memória de longo prazo (LSTM) lidam com a dependência temporal ([HOCHREITER; SCHMIDHUBER, 1997](#)).

Dessa forma, a profundidade dessas redes permite que o sistema capture desde detalhes mínimos de um frame até o contexto completo de uma frase em Libras. Conforme destacam [Fleck et al. \(2016\)](#), essa estrutura multicamada é essencial para que o modelo aprenda padrões que seriam invisíveis para algoritmos de aprendizado mais simples.

2.3.8 Redes Neurais Convolucionais (CNN)

As Redes Neurais Convolucionais (CNN) são arquiteturas de aprendizado profundo especializadas no processamento de dados com topologia em grade, como imagens e sequências. Introduzidas por [LeCun et al. \(1998\)](#) e popularizadas com o modelo AlexNet ([KRIZHEVSKY; SUTSKEVER; HINTON, 2012](#)), as CNNs revolucionaram o campo da visão computacional ao substituir a extração manual de características por um processo de aprendizado automático e hierárquico.

No escopo deste trabalho, a CNN é utilizada para o reconhecimento de sinais estáticos, como as configurações de mão do alfabeto manual da Libras, nos quais a identificação do sinal depende exclusivamente da configuração espacial da mão em um único *frame* ([FLECK et al., 2016](#)).

A arquitetura de uma CNN é composta por três tipos principais de camadas que se alternam e se combinam ao longo da rede ([GOODFELLOW; BENGIO; COURVILLE, 2016](#)):

1. Camada de Convolução: É o bloco fundamental da CNN. Nela, um conjunto de filtros (também chamados de *kernels*) de tamanho reduzido, tipicamente 3×3 ou 5×5 pixels, desliza sobre a imagem de entrada, calculando o produto escalar entre os pesos do filtro e os pixels da região coberta. Matematicamente, para uma imagem de entrada I e um filtro K , a operação de convolução discreta é definida como:

$$(I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n) \quad (2.1)$$

I : Imagem de entrada.

K : Filtro ou *kernel*.

(i, j) : Posição atual do pixel na saída (mapa de características).

(m, n) : Índices do *kernel*.

O resultado é chamado de mapa de ativação, que representa a presença de um determinado padrão visual (como bordas, curvas ou texturas) em cada posição espacial da imagem (GOODFELLOW; BENGIO; COURVILLE, 2016). O compartilhamento de pesos entre todas as posições da imagem reduz drasticamente o número de parâmetros treináveis e confere à CNN invariância à translação, o modelo reconhece o padrão independentemente de onde ele aparece na imagem (FLECK et al., 2016).

2. Camada de Pooling: Após a convolução, a camada de *pooling* realiza uma subamostragem espacial dos mapas de ativação, reduzindo suas dimensões e, com isso, a quantidade de parâmetros e o custo computacional das camadas subsequentes. A operação mais comum é o Max Pooling, que seleciona o valor máximo dentro de uma janela de tamanho fixo (por exemplo, 2×2), retendo as características mais proeminentes e descartando informações redundantes (LECUN et al., 1998). Esse mecanismo também contribui para a robustez do modelo a pequenas variações de posição e escala dos objetos.
3. Camadas Totalmente Conectadas: Ao final da rede, após um conjunto de camadas de convolução e *pooling*, os mapas de ativação são linearizados e alimentados em uma ou mais camadas totalmente conectadas, que funcionam como um classificador tradicional. Nessa etapa, as representações abstratas aprendidas pelas camadas anteriores são combinadas para gerar a predição final, por exemplo, a probabilidade de que o gesto capturado corresponda a cada letra do alfabeto manual (FURTADO, 2019).

No contexto deste projeto, os *landmarks* extraídos pelo MediaPipe (coordenadas x , y , z das articulações da mão) são organizados como vetores de entrada para a CNN. A rede aprende, durante o treinamento, quais combinações de posições articulares são discriminativas para cada sinal estático.

Conforme apontam [Fleck et al. \(2016\)](#), o sucesso das CNNs em tarefas de visão computacional deve-se à sua capacidade de identificar características locais de forma hierárquica: as camadas iniciais capturam padrões simples (orientação dos dedos, curvatura das juntas) e as camadas mais profundas combinam esses padrões em representações de alto nível (configuração completa da mão). Essa configuração garante maior robustez a variações de iluminação e enquadramento ([FURTADO, 2019](#)).

2.3.9 Redes de Memória de Longo Prazo (LSTM)

Para o reconhecimento de sinais dinâmicos em vídeo, onde o significado do gesto reside no movimento ao longo do tempo, utiliza-se a Long Short-Term Memory (LSTM). Esta arquitetura é uma evolução das Redes Neurais Recorrentes (RNN) tradicionais, introduzida por [Hochreiter e Schmidhuber \(1997\)](#) para solucionar a limitação do desaparecimento do gradiente (vanishing gradient), que impede redes comuns de aprenderem dependências de longo prazo em sequências de dados.

O diferencial da LSTM é a sua unidade de memória interna, frequentemente chamada de célula, que permite a manutenção de informações por intervalos de tempo estendidos ([HOCHREITER; SCHMIDHUBER, 1997](#)). Essa estrutura é fundamental para o aprendizado de sequências complexas, como a linguagem de sinais, onde a predição ou classificação de um gesto depende de frames ocorridos em instantes anteriores ([BAYER et al., 2009](#)).

A arquitetura da LSTM é composta por três componentes principais, conhecidos como "portões"(gates), que controlam o fluxo de informação:

1. Portão de Esquecimento (Forget Gate): decide qual informação do estado anterior deve ser descartada;
2. Portão de Entrada (Input Gate): seleciona quais novas informações serão armazenadas no estado da célula;
3. Portão de Saída (Output Gate): determina qual parte do estado interno será enviada como saída para o próximo passo temporal (([CONTARINI, 2020](#)); ([ALMEIDA, 2019](#))).

No contexto do tradutor de Libras, essa capacidade de retenção temporal permite que o sistema compreenda que a trajetória e a transição entre as poses das mãos são tão importantes quanto a configuração isolada em um único frame ([ALMEIDA, 2019](#)). Como destacado por [Schmidhuber \(2014\)](#), a profundidade dessas redes em termos de passos temporais possibilita a extração de representações abstratas que conectam movimentos manuais a conceitos semânticos complexos, garantindo maior precisão na interpretação de sinais dinâmicos.




Figura 4 – Diagrama de Rede Neural LSTM.

Autoria própria (2026).

2.3.10 Custo Computacional e Peso dos Modelos

O custo computacional refere-se à quantidade de recursos necessários para executar um modelo, incluindo uso de memória, processamento e capacidade de armazenamento. Já o peso do modelo está relacionado ao número de parâmetros treináveis presentes na rede neural, influenciando diretamente seu tamanho e complexidade.

Modelos mais complexos, como redes profundas com múltiplas camadas, tendem a apresentar maior precisão, porém demandam mais recursos computacionais. Conforme discutido por [Goodfellow, Bengio e Courville \(2016\)](#), o aumento da profundidade das redes neurais eleva sua capacidade de representação, mas também implica maior custo de processamento e necessidade de hardware mais robusto.

No contexto deste trabalho, a escolha das arquiteturas busca equilibrar desempenho e eficiência, considerando a necessidade de processamento em tempo execução. Estratégias como o uso de landmarks, redução de dimensionalidade dos dados e limitação do vocabulário inicial contribuem para diminuir o custo computacional.

Esse equilíbrio é fundamental para garantir que o sistema seja não apenas preciso, mas também utilizável em cenários práticos.

2.3.11 Reconhecimento de Gestos (Gesture Recognition)

O reconhecimento de gestos é uma parte da visão computacional que visa identificar e interpretar movimentos ou posições do corpo humano a partir de dados visuais, transformando-os em comandos ou símbolos compreensíveis por máquinas (SILVA, 2017). No contexto da Língua Brasileira de Sinais (Libras), essa técnica é o pilar fundamental para a tradução automatizada, permitindo que a interação entre surdos e ouvintes ocorra de forma fluida através da interface homem-máquina (OSÓRIO, 2002).

Os gestos são geralmente classificados em duas categorias principais, cada uma exigindo abordagens algorítmicas distintas:

- **Estáticos (Imagem):** Referem-se à configuração ou postura da mão em um único instante. O foco recai sobre a forma, a orientação e a posição dos dedos, como ocorre na representação do alfabeto manual ou numerais em Libras (JÚNIOR, 2019). Redes Neurais Convolucionais (CNNs) são frequentemente aplicadas para extrair padrões espaciais nessas imagens estáticas.
- **Dinâmicos (Vídeo):** Envolvem uma sequência de movimentos ao longo do tempo, onde a trajetória e a velocidade são cruciais para o significado do sinal (SILVA, 2017). Para interpretá-los, utilizam-se técnicas que consideram a continuidade temporal, como a subtração de quadros sucessivos para detecção de movimento ou o uso de grafos de ação e aprendizado de métricas para reconhecimento em tempo de execução (MONTEIRO et al., 2016).

A implementação eficaz desses sistemas enfrenta desafios significativos que podem comprometer a taxa de acerto do reconhecimento. As variações de iluminação representam um dos principais obstáculos, pois alterações na luz do ambiente modificam os valores dos pixels e dificultam a segmentação precisa da pele (OSÓRIO, 2002).

Além disso, a variabilidade entre usuários introduz complexidade, uma vez que diferentes pessoas possuem características físicas distintas e executam o mesmo sinal com velocidades e amplitudes diversas, exigindo modelos robustos e generalistas (SILVA, 2017).

Por fim, a influência do fundo da imagem (background) pode impactar a precisão, especialmente em cenários com muitos objetos ou cores semelhantes ao tom da pele humana, o que torna essencial o uso de filtros adaptativos ou técnicas de segmentação para isolar adequadamente a mão do restante da cena (MONTEIRO et al., 2016).

2.3.12 Processamento de Linguagem Natural (NLP)

O Processamento de Linguagem Natural é uma vertente da Inteligência Artificial que visa capacitar sistemas computacionais a compreender, interpretar e gerar a linguagem humana, tanto em formato de texto. Segundo Cole Stryker and Jim Holdsworth (2024), o NLP combina a linguística estatística e computacional com modelos de aprendizado

profundo para processar a linguagem em formas que exibam compreensão de significado e intenção.

No escopo deste projeto, o reconhecimento isolado de gestos por meio de visão computacional não é suficiente para uma comunicação fluida, dada a profunda divergência gramatical entre a Libras e a língua portuguesa. Conforme apontam [Lopez e Kalita \(2017\)](#), o uso de redes neurais aplicadas ao NLP permite que o sistema lide com a ambiguidade inerente à linguagem e aprenda representações hierárquicas dos dados textuais. O módulo de NLP atua, portanto, como uma camada de pós-processamento essencial, realizando a conversão semântica e sintática dos sinais identificados pela rede neural.

A abordagem adotada neste trabalho é um pipeline de processamento sequencial, implementado com a biblioteca spaCy ([HONNIBAL et al., 2020](#)), composta por 4 etapas, tokenização e normalização, etiquetagem morfossintática, análise de dependência sintática e reordenação sintática e concordância.

Os sinais identificados pela etapa de visão computacional chegam ao módulo de NLP como uma sequência de *tokens*, palavras isoladas na estrutura da Libras (ex.: [VOCÊ, QUERER, ÁGUA]). A tokenização consiste em tratar cada sinal como uma unidade lexical discreta, e a normalização realiza a lematização de cada token, reduzindo as formas flexionadas à forma canônica (lema), o que facilita o mapeamento para o português ([BIRD; KLEIN; LOPER, 2009](#)).

Cada token recebe uma etiqueta morfossintática (substantivo, verbo, pronome, etc.). No spaCy, esse processo é realizado por um modelo de rede neural treinado sobre corpora anotados ([HONNIBAL et al., 2020](#)). Formalmente, dado um vocabulário $\mathcal{V}$ e um conjunto de etiquetas $\mathcal{T}$, o *tagger* aprende uma função $f : \mathcal{V}^n \rightarrow \mathcal{T}^n$ que maximiza a probabilidade conjunta da sequência de etiquetas dado o contexto da sentença.

Após a etiquetagem, o analisador de dependências identifica as relações gramaticais entre os tokens (sujeito, objeto, modificador, etc.), produzindo uma árvore de dependência sintática.

Com base nas relações identificadas pela árvore de dependência, o módulo reordena os tokens segundo a estrutura SVO do português e aplica regras de concordância nominal e verbal. Por exemplo, a sequência da Libras [VOCÊ, QUERER, ÁGUA] é reescrita como “*Você quer água.*”, com a flexão verbal adequada ao sujeito identificado ([LOPEZ; KALITA, 2017](#)).

Formalmente, seja $S_L = (w_1, w_2, \dots, w_n)$ a sequência de sinais identificados na estrutura da Libras e S_P a frase-alvo em português. O módulo de NLP aprende uma função de reordenação π tal que:

$$S_P = \text{Flexão}(\pi(S_L), G_{\text{pt}}) \quad (2.2)$$

onde π é uma permutação dos índices dos tokens guiada pelas relações de dependência e G_{pt} representa as regras gramaticais do português, incluindo concordância de gênero,

número e tempo verbal (BIRD; KLEIN; LOPER, 2009).




Figura 5 – Diagrama de Processamento de Linguagem Natural - NLP.

Autoria própria (2026).

2.3.13 Árvores de Dependência Sintática

Uma árvore de dependência sintática é uma estrutura de dados que representa as relações gramaticais binárias e assimétricas entre os tokens de uma sentença. Diferentemente das gramáticas de constituintes (baseadas em sintagmas), a análise de dependência conecta diretamente pares de palavras: uma cabeça e um dependente, com uma etiqueta que nomeia o tipo de relação (*nsubj* para sujeito nominal, *obj* para objeto direto, *advmod* para modificador adverbial, etc.) (JURAFSKY; MARTIN, 2023).

Formalmente, dada uma sentença $s = (w_1, w_2, \dots, w_n)$, uma árvore de dependência é um grafo dirigido $G = (V, A)$ onde:

- $V = \{w_0, w_1, \dots, w_n\}$ é o conjunto de vértices (tokens mais um nó raiz artificial w_0);
- $A \subseteq V \times V \times \mathcal{R}$ é o conjunto de arcos rotulados, onde cada arco (w_i, w_j, r) indica que w_i é a cabeça de w_j com relação do tipo $r \in \mathcal{R}$;
- cada token (exceto a raiz) possui exatamente uma cabeça, garantindo a estrutura de árvore (JURAFSKY; MARTIN, 2023).

Como exemplo, considere a sentença “*Você quer água.*” Sua árvore de dependência teria *quer* como raiz (verbo principal), com *Você* ligado a ela pelo arco *nsubj* (sujeito nominal) e *água* pelo arco *obj* (objeto direto).

No presente trabalho, a análise de dependência é realizada pela biblioteca spaCy (HONNIBAL et al., 2020), que implementa um analisador neural baseado em transições (*transition-based parser*). Esse analisador processa a sentença da esquerda para a direita, mantendo uma pilha e uma fila de tokens, e a cada passo aplica uma das três operações possíveis: *SHIFT* (empilha o próximo token), *LEFT-ARC* (cria um arco da cabeça para o dependente à esquerda) ou *RIGHT-ARC* (cria um arco da cabeça para o dependente à direita). A escolha da operação é feita por um classificador neural que considera o contexto da pilha e da fila (HONNIBAL et al., 2020).

A adoção de árvores de dependência é especialmente adequada para este projeto por três razões. Primeiro, como a Libras apresenta ordem frasal flexível (SVO, SOV, OSV, entre outras), a análise de dependência é robusta a variações de ordem, pois identifica as relações semânticas independentemente da posição linear dos tokens (JURAFSKY; MARTIN, 2023). Segundo, a estrutura arbórea explicita quais tokens são sujeito, objeto e predicado, fornecendo ao módulo de reordenação a informação necessária para reconstruir a sentença na estrutura SVO do português. Terceiro, as etiquetas de dependência permitem aplicar regras de concordância dirigidas: identificado o sujeito (*nsubj*), é possível flexionar o verbo-cabeça no número e pessoa correspondentes (BIRD; KLEIN; LOPER, 2009).

Dessa forma, as árvores de dependência atuam como a representação intermediária que conecta a saída do reconhecedor de gestos (sequência de tokens na ordem da Libras) à frase final gramaticalmente correta em português, tornando o pipeline de tradução mais explícito, interpretável e extensível.

2.3.14 Integração Visão Computacional + NLP

A integração entre visão computacional e processamento de linguagem natural é essencial para o funcionamento do sistema proposto. Essa combinação permite não apenas reconhecer os sinais, mas também convertê-los em linguagem compreensível.

O processo ocorre em etapas, iniciando pela captura de vídeo, seguida pelo reconhecimento dos sinais por meio de modelos de visão computacional, e finalizando com a conversão desses sinais em texto por meio de técnicas de NLP.

Um dos principais desafios dessa integração está na necessidade de transformar sinais isolados em frases coerentes, respeitando as regras gramaticais da língua portuguesa. Dessa forma, o sistema não se limita ao reconhecimento de gestos, mas busca realizar uma tradução mais completa e significativa.

2.3.15 Acurácia e Matriz de Confusão

A acurácia é uma das métricas mais fundamentais para a avaliação de modelos de classificação. Ela expressa a proporção de predições corretas em relação ao total de exemplos avaliados, oferecendo uma visão geral do desempenho do sistema (GOODFELLOW; BENGIO; COURVILLE, 2016). Apesar de sua interpretação direta, a acurácia isolada pode ser insuficiente em contextos com muitas classes, pois não revela quais sinais estão sendo confundidos entre si, informação essencial para o refinamento do modelo.

Para suprir essa limitação, utiliza-se a matriz de confusão, uma representação tabular que cruza as classes reais com as classes preditas. Cada célula indica quantas amostras de uma determinada classe foram classificadas como outra, permitindo identificar padrões de erro específicos. Por exemplo, quais pares de sinais o modelo tende a confundir com maior frequência devido à semelhança na configuração de mão ou no movimento (GOODFELLOW; BENGIO; COURVILLE, 2016). A partir dela, derivam-se ainda métricas complementares como precisão e *recall*, que expõem desequilíbrios de desempenho entre as classes de forma mais granular.

No escopo desta pesquisa, a acurácia e a matriz de confusão serão utilizadas para avaliar o módulo de visão computacional, tanto na classificação de sinais estáticos pela CNN quanto no reconhecimento de sinais dinâmicos pela LSTM. A análise conjunta dessas métricas permitirá identificar os sinais com maior taxa de erro e orientar ajustes no modelo ou na composição do dataset de treinamento.

Com essa abordagem, busca-se garantir que o sistema apresente desempenho equilibrado entre todos os sinais do vocabulário definido, e não apenas nas classes mais frequentes.

2.3.16 Métrica BLEU

A métrica BLEU (*Bilingual Evaluation Understudy*), proposta por Papineni et al. (2002), é o padrão consolidado para avaliação automática de qualidade em sistemas de tradução. Ela compara o texto gerado pelo sistema com traduções humanas de referência, mensurando a sobreposição de sequências de palavras conhecidas como n -gramas. Esses elementos representam agrupamentos contínuos de n itens; enquanto os unigramas ($n = 1$) avaliam a presença de palavras isoladas, os bigramas ($n = 2$) e trigramas ($n = 3$) permitem verificar se a ordem e o contexto gramatical foram preservados. Quanto maior a correspondência com as referências humanas, mais alto o score BLEU, que varia de 0 a 1.

O uso do BLEU é especialmente relevante neste projeto porque o módulo de NLP não apenas transcreve sinais isolados, mas reorganiza e flexiona as palavras para gerar frases coerentes em português, um processo criativo que não pode ser avaliado somente por acurácia. Conforme apontam Papineni et al. (2002), a métrica captura tanto a precisão lexical quanto aspectos da fluência, ao penalizar hipóteses que se distanciam estruturalmente das referências humanas.

Para a validação do sistema proposto, o BLEU será calculado comparando as frases em português produzidas pelo sistema com traduções de referência elaboradas por especialistas para o mesmo conjunto de sinais de entrada. Escores mais altos indicam que o módulo de NLP está gerando saídas linguisticamente próximas ao que um humano produziria a partir dos mesmos sinais.

Nesse sentido, o BLEU complementa as métricas de reconhecimento gestual ao avaliar especificamente a qualidade da camada linguística do sistema, fechando o ciclo de avaliação do pipeline completo de tradução.

2.3.17 Latência e Tempo de Resposta

A latência corresponde ao tempo decorrido entre a captura do sinal pelo sistema e a exibição da tradução ao usuário. Em aplicações de tradução em tempo real, esse fator é crítico, pois impacta diretamente a experiência de uso e a fluidez da comunicação.

Sistemas com alta latência podem gerar atrasos perceptíveis, comprometendo a interação entre os usuários. Por isso, é necessário otimizar todas as etapas do pipeline, desde a captura do vídeo até o processamento pelos modelos e a geração da saída textual.

De acordo com [Molchanov et al. \(2015\)](#), em sistemas de reconhecimento de gestos em tempo real, o desempenho está diretamente relacionado à eficiência computacional dos modelos e à capacidade de processar sequências de vídeo com baixa latência.

No presente trabalho, a latência será considerada como um dos principais critérios de avaliação do sistema. A utilização de técnicas como processamento eficiente de frames, redução do tamanho dos dados (por meio de landmarks) e escolha de modelos com menor custo computacional contribui para minimizar o tempo de resposta.

Dessa forma, busca-se garantir que a tradução ocorra de forma rápida e contínua, aproximando-se de uma comunicação natural.

2.4 Trabalhos relacionados

2.4.1 Trabalho 1: Sign Language Translator System Using Computer Vision and LSTM Neural Networks

O estudo de [Wang, Jiang e Li \(2025\)](#) investigou o problema da dificuldade de comunicação entre pessoas surdas e ouvintes, causada pela falta de compreensão da língua de sinais, o que impacta diretamente o acesso a serviços e interações sociais — o mesmo problema abordado neste trabalho.

Para enfrentar essa questão, os autores desenvolveram um sistema de tradução de língua de sinais em tempo real, combinando técnicas de visão computacional, redes neurais convolucionais (CNN), redes recorrentes do tipo LSTM e processamento de linguagem natural.

A metodologia incluiu a coleta e anotação de um dataset de gestos, seguido do treinamento de modelos capazes de reconhecer sinais e convertê-los em texto automaticamente.

Os resultados obtidos demonstraram uma precisão de 97% no reconhecimento dos gestos, indicando que a abordagem é eficaz para cenários controlados. Além disso, o sistema mostrou potencial para melhorar a acessibilidade e a inclusão social.

Entretanto, a solução apresenta limitações importantes, como a dependência de condições ambientais controladas (iluminação e fundo), a escassez de datasets amplos, e dificuldades em manter desempenho em tempo real. Também há restrições relacionadas à acessibilidade, especialmente em sistemas baseados na web que dependem de conexão com a internet.

Diferentemente desse trabalho, a presente pesquisa propõe uma abordagem mais integrada, ao não apenas reconhecer os sinais, mas também estruturá-los linguisticamente por meio de processamento de linguagem natural, buscando gerar frases coerentes em português, e não apenas transcrições diretas de sinais.

2.4.2 Trabalho 2: Interpretação de gestos de Libras usando K-Means e Random Forest

[Caiafa et al. \(2023\)](#) propuseram uma solução para o reconhecimento automático de sinais da Libras com foco em reduzir o custo computacional, mantendo uma boa acurácia. O problema tratado também está relacionado à barreira de comunicação entre usuários e não usuários da língua de sinais, sendo, portanto, diretamente alinhado com esta pesquisa.

A abordagem adotada pelos autores difere das soluções baseadas exclusivamente em deep learning, pois utiliza o MediaPipe para extração de pontos-chave corporais, seguido de técnicas de agrupamento com K-Means e classificação utilizando algoritmos como KNN e Random Forest. Essa metodologia permite trabalhar com representações mais leves dos dados, reduzindo o processamento necessário.

Os experimentos foram realizados utilizando a base de dados MINDS-Libras, resultando em uma acurácia de 94,72

Apesar dos bons resultados, o trabalho apresenta limitações, principalmente no fato de que o sistema foca apenas na classificação de sinais isolados, sem tratar a construção de frases ou o contexto linguístico. Além disso, ainda enfrenta desafios comuns da área, como variações de iluminação, ângulo de câmera e aumento do vocabulário.

O presente trabalho avança em relação a essa proposta ao incorporar, além da etapa de reconhecimento, um módulo de processamento de linguagem natural, responsável por organizar os sinais identificados em frases estruturadas em português, ampliando o nível de interpretação da comunicação.

2.4.3 Trabalho 3: Detection and Interpretation of Indian Sign Language Using LSTM Networks

Vyavahare et al. (2023) abordaram o desenvolvimento de um sistema para reconhecimento e interpretação da língua de sinais indiana (ISL) em tempo real, com o objetivo de reduzir a lacuna comunicacional entre pessoas com deficiência auditiva e a sociedade — problema equivalente ao tratado neste TCC.

A solução proposta baseia-se no uso de técnicas de visão computacional para extração de características visuais, combinadas com redes neurais recorrentes do tipo LSTM, capazes de capturar dependências temporais em gestos dinâmicos. Os autores também criaram um dataset próprio, composto por vídeos anotados de usuários nativos de ISL.

Os resultados experimentais indicaram um desempenho elevado, com 96

No entanto, o estudo apresenta algumas limitações relevantes. A principal delas é que o sistema está restrito ao reconhecimento de palavras isoladas, não sendo capaz de interpretar frases completas. Além disso, o desempenho pode ser afetado por fatores como variações de iluminação, ângulo de câmera e posicionamento das mãos.

Este trabalho se diferencia ao propor uma solução que vai além do reconhecimento de gestos individuais, incorporando uma camada de processamento de linguagem natural para construção de frases, buscando uma tradução mais próxima da comunicação real entre Libras e língua portuguesa.

Tabela 1 – Comparação entre trabalhos relacionados

Critério	Trabalho 1	Trabalho 2	Trabalho 3	Este trabalho
Objetivo	Tradução de sinais em tempo real para texto.	Classificação de sinais de Libras com baixo custo computacional.	Reconhecimento e interpretação de sinais dinâmicos (ISL).	Tradução de Libras com estrutura gramatical de frases.
Tecnologia	CNN, LSTM e PLN básico.	MediaPipe, K-Means, KNN e Random Forest.	Visão Computacional (OpenCV) e LSTM.	Arquitetura híbrida CNN + LSTM e camada robusta de PLN.
Validação	Dataset próprio (webcam); Acurácia de 97%.	Base pública MINDS-Libras; Acurácia de 94,72%.	Dataset próprio (ISL); 96% treino e 87% teste.	Dataset de Libras, métricas de acurácia e avaliação sintática.
Limitação	Sensível à iluminação e dependência de conexão web.	Classificação restrita a sinais/palavras isoladas.	Não interpreta frases completas ou contexto linguístico.	Dependência de dataset abrangente para diversidade de sinais.

Autoria própria (2026).

3 Desenvolvimento

Neste capítulo, apresenta-se a solução proposta para o problema de tradução automática da Língua Brasileira de Sinais (Libras) para a língua portuguesa. A descrição contempla a visão geral do sistema, sua arquitetura, as tecnologias selecionadas, as funcionalidades principais, a metodologia de desenvolvimento adotada e os critérios de validação que serão utilizados para avaliar o desempenho da solução.




Figura 6 – Diagrama de fluxo da solução proposta.

Autoria própria (2026).

3.1 Solução proposta

3.1.1 Visão geral da solução

A solução proposta consiste em um sistema desktop de tradução automática em tempo execução, capaz de reconhecer gestos da Língua Brasileira de Sinais por meio de visão computacional e convertê-los em texto da língua portuguesa. O sistema é voltado para uso em computadores com câmera integrada, sendo projetado para funcionar como um facilitador de comunicação em contextos como atendimentos, ambientes educacionais e interações cotidianas.

A aplicação é composta por três módulos principais integrados em um pipeline de processamento sequencial: (i) o módulo de visão computacional, responsável pela captura e reconhecimento dos sinais; (ii) o módulo de processamento de linguagem natural, responsável pela conversão dos tokens reconhecidos em frases coerentes em português; e (iii) a interface do usuário, que exibe a tradução em tempo execução.

Em razão da amplitude lexical da Libras e do caráter experimental deste estudo, o vocabulário inicial do sistema abrangerá um conjunto definido de sinais voltados a contextos de comunicação básica, como cumprimentos, solicitações de ajuda, identificação pessoal e situações de atendimento.




Figura 7 – Fluxograma de Execução do Pipeline.

Autoria própria (2026).

3.1.2 Arquitetura

A arquitetura do sistema é organizada de forma modular, dividida em três camadas principais de processamento que interagem sequencialmente para garantir a precisão da tradução:

1. Camada de Aquisição e Visão (Front-end/Captura): Responsável por receber o fluxo de vídeo e utilizar algoritmos de extração de landmarks para isolar os movimentos das mãos e do corpo.
2. Camada de Inteligência (Processamento Híbrido): O núcleo da solução, onde Redes Neurais Convolucionais (CNN) processam a geometria espacial de cada frame e Redes de Memória de Longo Prazo (LSTM) interpretam a continuidade temporal dos movimentos.
3. Camada de Interpretação Linguística (NLP): Módulo que recebe os sinais identificados (tokens) e aplica regras de Processamento de Linguagem Natural para gerar frases gramaticalmente corretas em língua portuguesa.




Figura 8 – Fluxo de Processamento da Arquitetura Híbrida.

Autoria própria (2026).

3.1.3 Tecnologias e ferramentas

As escolhas tecnológicas foram feitas visando o alto desempenho em processamento de tensores e visão computacional:

- Linguagem de Programação: Python, devido à sua maturidade e vasta biblioteca para IA.
- Frameworks de Inteligência Artificial: TensorFlow ou Keras para o desenvolvimento das arquiteturas CNN e LSTM.
- Visão Computacional: MediaPipe ou OpenCV para a extração ágil de pontos de referência (landmarks) das mãos.
- Dataset: Minds-Libras, Libras Brazilian Sign Language e V-BrasilIL escolhidos pela diversidade de sinais e qualidade das anotações.


- Processamento de Texto: Biblioteca NLTK ou spaCy para as tarefas de NLP e adequação gramatical.

3.1.4 Funcionalidades principais

Para atingir os objetivos propostos, o sistema disponibilizará as seguintes funcionalidades:

- Captura de Sinais em Tempo Real: Processamento de vídeo via webcam com baixa latência.
- Reconhecimento de Sinais Estáticos e Dinâmicos: Capacidade de traduzir desde o alfabeto manual até gestos complexos em movimento.

Figura 9 – Alfabeto de Libras.



Fonte: Segredos do Mundo (2026).

- Tradução Sintática Automática: Reorganização de sentenças da estrutura Libras para a estrutura SVO do português.
- Saída Multimodal: Exibição da tradução em texto na tela.

3.1.5 Metodologia de desenvolvimento

O projeto adotará a metodologia ágil Scrum, organizada em ciclos de desenvolvimento (Sprints). A escolha justifica-se pela natureza experimental de modelos de IA, permitindo testes contínuos e ajustes refinados nos hiperparâmetros das redes neurais a cada entrega parcial (prototipação).

3.1.6 Critérios de validação

O sucesso da solução será medido através de métricas quantitativas e qualitativas:

- Acurácia e Precisão: Medição da taxa de acerto do modelo na classificação dos sinais utilizando uma matriz de confusão.
- Métrica BLEU (Bilingual Evaluation Understudy): Utilizada para avaliar a qualidade da tradução gerada pelo módulo de NLP em comparação com traduções humanas.
- Tempo de Resposta: Testes de latência para garantir que a tradução ocorra em tempo de execução.

3.2 Cronograma de trabalho

O cronograma a seguir apresenta, no formato de diagrama de Gantt, as atividades previstas para o desenvolvimento do TCC2, distribuídas ao longo das semanas do semestre.




Figura 10 – Cronograma de atividades – Diagrama de Gantt

Autoria própria (2026).

Referências

- ALMEIDA, R. C. de. *Uso de Redes Neurais Long Short-Term Memory como Estratégia de Algorithmic Trading*. Dissertação (Projeto de Graduação (Engenharia Elétrica)) — Universidade Federal do Espírito Santo, Vitória, 2019. 18
- BAYER, J. et al. Evolving memory cell structures for sequence learning. Springer, Manno-Lugano, p. 755 – 764, 2009. 18
- BIRD, S.; KLEIN, E.; LOPER, E. *Natural Language Processing with Python*. [S.l.]: O'Reilly Media, 2009. 21, 22, 23
- CAIAFA, E. G. de A. et al. Interpretação de gestos de libras usando k-means e random forest. *XLI Simpósio Brasileiro De Telecomunicações E Processamento De Sinais (SBrT2023)*, 2023. 26
- CHAWLA, N. V. et al. SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, v. 16, p. 321–357, 2002. 12
- Cole Stryker and Jim Holdsworth. *O que é processamento de linguagem natural (NLP)?* 2024. Acesso em: 19 abr. 2026. Disponível em: <<https://www.ibm.com/br-pt/think/topics/natural-language-processing>>. 20
- CONTARINI, G. *Redes Neurais LSTM e Modelo GARCH: Uma Abordagem Conjunta para Previsão de Retornos*. Dissertação (Monografia (Bacharelado em Economia)) — Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2020. 18
- Dave Bergmann. *O que é visão computacional?* 2025. Acesso em: 15 abr. 2026. Disponível em: <<https://www.ibm.com/br-pt/think/topics/computer-vision>>. 12
- Dave Bergmann. *O que é deep learning?* 2026. Acesso em: 19 abr. 2026. Disponível em: <<https://www.ibm.com/br-pt/think/topics/deep-learning>>. 15
- FELIPE, T. A. *O discurso verbo-visual na língua brasileira de sinais - Libras*. 2013. Acesso em: 07 maio 2025. Disponível em: <<https://www.scielo.br/j/bak/a/MJ378DGggYhnmTfCFzh6VRy/?lang=pt>>. 10
- FLECK, L. et al. Redes neurais artificiais: Princípios básicos. *Revista Eletrônica Científica Inovação e Tecnologia*, v. 7, n. 15, p. 47–57, 2016. 16, 17, 18
- FURTADO, M. I. V. *Redes Neurais Artificiais: Uma Abordagem Para Sala de Aula*. 1. ed. Ponta Grossa, PR: Atena Editora, 2019. 17, 18
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Aprendizado Profundo*. Cambridge: MIT Press, 2016. 11, 12, 16, 17, 19, 24
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *MIT Press*, v. 9, n. 8, p. 1735 – 1780, 1997. 16, 18
- HONNIBAL, M. et al. *spaCy: Industrial-strength Natural Language Processing in Python*. 2020. Software. Disponível em: <<https://spacy.io>>. Acesso em: 30 abr. 2026. 21, 23

- IBGE. *Pesquisa Nacional de Saúde*. 2019. Acesso em: 16 abr. 2026. Disponível em: <<https://sidra.ibge.gov.br/tabela/8223>>. 5
- JUNG, D. *Microservices: a definition of this new architectural term*. 2021. Acesso em: 07 maio 2025. Disponível em: <<https://stackoverflow.com/questions/68045164/how-to-get-the-coordinates-of-the-dots-in-hand-image>>. 14
- JURAFSKY, D.; MARTIN, J. H. *Speech and Language Processing*. 3. ed. [S.l.]: Prentice Hall, 2023. Rascunho online. Disponível em: <<https://web.stanford.edu/~jurafsky/slp3/>>. 22, 23
- JÚNIOR, R. F. P. *Utilização de inteligência artificial na tradução de língua gestual para língua verbal*. Dissertação (Dissertação (Mestrado em Engenharia Elétrica e de Computação)) — Universidade Federal do Ceará, Sobral, 2019. 20
- KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. ImageNet classification with deep convolutional neural networks. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2012. v. 25. 16
- LECUN, Y. et al. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, v. 86, n. 11, p. 2278–2324, 1998. 16, 17
- LOPEZ, M. M.; KALITA, J. Deep learning applied to nlp. *arXiv preprint arXiv:1703.03091*, 2017. 21
- LUGARESI, C. et al. Mediapipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*, 2019. 14, 15
- MILANO, D. de; HONORATO, L. B. *Uso de Redes Neurais Long Short-Term Memory como Estratégia de Algorithmic Trading*. Dissertação (Artigo (Faculdade de Tecnologia)) — Universidade Estadual de Campinas, Limeira, 2014. 12, 13
- MOLCHANOV, P. et al. Hand gesture recognition with 3d convolutional neural networks. *IEEE*, p. 1–7, 2015. 25
- MONTEIRO, C. H. de A. et al. Um sistema de baixo custo para reconhecimento de gestos em libras utilizando visão computacional. *XXXIV Simpósio Brasileiro De Telecomunicações - SBrT2016*, 2016. 20
- NEVES, L. A. P.; NETO, H. V.; GONZAGA, A. *Avanços em visão computacional*. 1. ed. Paraná: Omnipax, 2012. 13
- OLIZAROSKI, I. M. H.; MOLIN, B. H. D. Diferenças gramaticais entre a libras e a língua portuguesa com Ênfase à conjugação e transitividade verbal. *Revista Advérbio*, v. 18, n. 35, 2024. 5
- Oracle. *O que é deep learning?* 2022. Acesso em: 19 abr. 2026. Disponível em: <<https://www.oracle.com/br/artificial-intelligence/machine-learning/what-is-deep-learning/>>. 16
- OSÓRIO, J. R. de Bittencourt Menezes e F. S. O uso de redes neurais artificiais na detecção de pele em imagens digitais visando o reconhecimento de gestos. *Seminário de Computação - SEMINCO*, 2002. 20

- PAPINENI, K. et al. BLEU: a method for automatic evaluation of machine translation. In: *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*. [S.l.: s.n.], 2002. p. 311–318. 24
- PAS, B. T. *Brazilian Sign Language Alphabet Dataset*. 2020. Mendeley Data. Disponível em: <<https://data.mendeley.com/datasets/k4gs3bmx5k>>. Acesso em: 30 abr. 2026. 12
- PINHO, R. R.; TAVARES, J. M. R. S.; CORREIA, M. F. P. V. *Introdução à Análise de Movimento usando Visão Computacional*. Dissertação (Relatório Interno (Engenharia e Gestão Industrial)) — Universidade do Porto, Porto, 2004. 13
- QUADROS, R. M. de; KARNOPP, L. B. *Língua de Sinais: Estudos Linguísticos*. 1. ed. Porto Alegre: ArtMed, 2004. 9, 10
- REZENDE, T. M. *Reconhecimento automático de sinais da Libras: desenvolvimento da base de dados MINDS-Libras e modelos de redes convolucionais*. Tese (Doutorado) — Universidade Federal de Minas Gerais, Belo Horizonte, 2021. 12
- RODRIGUES, A. J. *V-LIBRASIL: uma base de dados com sinais na língua brasileira de sinais (Libras)*. Tese (Doutorado) — Universidade Federal de Pernambuco, Recife, 2021. 12
- SCHMIDHUBER, J. Deep learning in neural networks: An overview. *Neural Networks*, v. 61, p. 85 – 117, 2014. 11, 16, 18
- SILVA, S. R. *Reconhecimento de gestos customizados da mão em tempo real usando aprendizado de métricas e grafos de ação*. Dissertação (Dissertação (Mestrado em Instituto de Matemática)) — Universidade Federal de Alagoas, Maceió, 2017. 11, 20
- SZELISKI, R. *Computer Vision: Algorithms and Applications*. 2. ed. Ponta Grossa, PR: Springer, 2010. 11
- VYAVAHARE, P. et al. Detection and interpretation of indian sign language using lstm networks. *Journal of Intelligent Systems and Control*, 2023. 27
- WANG, Y.; JIANG, W.; LI, D. Sign language translator system using computer vision and lstm neural networks. *International Journal of Information Technologies and Systems Approach*, v. 18, 2025. 25
- ZHANG, F. et al. Mediapipe hands: On-device real-time hand tracking. In: *arXiv preprint arXiv:2006.10214*. [S.l.: s.n.], 2020. 14, 15