

Júlia Almeida Leite
Maria Eduarda Mariano Coelho

**Sistema Inteligente de Tradução de Libras
Utilizando Visão Computacional e
Processamento de Linguagem Natural**

São Paulo
2026

Júlia Almeida Leite
Maria Eduarda Mariano Coelho

Sistema Inteligente de Tradução de Libras Utilizando Visão Computacional e Processamento de Linguagem Natural

Proposta de Trabalho de Conclusão de Curso
apresentado ao SENAC Santo Amaro como
requisito parcial para aprovação na disciplina
de TCC1 do curso de Bacharelado em Ciência
da Computação.

SENAC – Serviço Nacional de Aprendizagem Comercial
Unidade Santo Amaro
Curso de Bacharelado em Ciência da Computação

Orientador: Prof. Thyago Conchado Quintas

São Paulo
2026

Resumo

Este trabalho propõe um sistema inteligente de tradução da Língua Brasileira de Sinais (Libras) para a língua portuguesa, integrando visão computacional, aprendizado profundo e modelos de linguagem em um pipeline unificado. A motivação parte da barreira comunicacional existente entre a comunidade surda e ouvintes, agravada pelo número reduzido de intérpretes disponíveis em situações cotidianas. A revisão bibliográfica abrange os fundamentos da Libras, técnicas de visão computacional com MediaPipe, arquiteturas de redes neurais convolucionais (CNN) e recorrentes (LSTM), processamento de linguagem natural com spaCy e modelos de linguagem de grande escala (LLM). A solução proposta é composta por quatro camadas: captura simultânea de landmarks manuais e faciais via MediaPipe, classificação gestual por CNN e LSTM, reorganização sintática por NLP e refinamento linguístico por LLM, produzindo frases gramaticalmente coerentes em português. O sistema foca em um domínio vocabular específico, selecionado a partir da análise dos datasets MINDS-Libras, V-Librasil e Libras Brazilian Sign Language. O desempenho será avaliado por acurácia, matriz de confusão, métrica BLEU, análise de latência e validação com usuários reais da comunidade surda.

Palavras-chave: Libras. Visão Computacional. Deep Learning. Processamento de Linguagem Natural. Modelos de Linguagem de Grande Escala.

Sumário

1	INTRODUÇÃO	5
1.1	Contexto	6
1.2	Justificativa	7
1.3	Hipótese	8
1.4	Objetivo	8
1.4.1	Objetivo principal	8
1.4.2	Objetivos secundários	8
2	REVISÃO BIBLIOGRÁFICA	10
2.1	Referencial teórico	10
2.2	Metodologia da pesquisa bibliográfica	12
2.3	Fundamentos	13
2.3.1	Inteligência Artificial (IA)	13
2.3.2	Machine Learning	14
2.3.3	Datasets	15
2.3.4	Pré-processamento de Dados	16
2.3.5	Visão Computacional	17
2.3.6	MediaPipe & Landmarks	18
2.3.7	Deep Learning	20
2.3.8	Redes Neurais Convolucionais (CNN)	21
2.3.9	Redes de Memória de Longo Prazo (LSTM)	23
2.3.10	Reconhecimento de Gestos (Gesture Recognition)	25
2.3.11	Árvores de Dependência Sintática	26
2.3.12	Processamento de Linguagem Natural (NLP)	27
2.3.13	Modelos de Linguagem de Grande Escala (LLM)	29
2.3.14	Custo Computacional e Peso dos Modelos	29
2.3.15	Acurácia & Precisão	30
2.3.16	Métrica BLEU	31
2.3.17	Latência e Tempo de Resposta	31
2.4	Trabalhos relacionados	32
2.4.1	Trabalho 1: Sign Language Translator System Using Computer Vision and LSTM Neural Networks	32
2.4.2	Trabalho 2: Interpretação de gestos de Libras usando K-Means e Random Forest	32

2.4.3	Trabalho 3: Detection and Interpretation of Indian Sign Language Using LSTM Networks	33
3	DESENVOLVIMENTO	35
3.1	Solução proposta	36
3.1.1	Visão geral da solução	36
3.1.2	Domínio de Aplicação e Seleção do Vocabulário	39
3.1.3	Tamanho do Vocabulário e Tipos de Sinais Suportados	39
3.1.4	Desafios do Sistema	40
3.1.5	Limitações do Sistema	40
3.1.6	Arquitetura	41
3.1.7	Tecnologias e ferramentas	42
3.1.8	Funcionalidades principais	43
3.1.9	Metodologia de desenvolvimento	43
3.1.10	Critérios de validação	43
3.2	Cronograma de trabalho	44
	REFERÊNCIAS	45

1 Introdução

A comunicação é extremamente importante para promover a inclusão social. No entanto, muitas pessoas surdas que utilizam a Língua Brasileira de Sinais (Libras) encontram barreiras na interação com aqueles que não conhecem essa linguagem. Essa limitação afeta diretamente o acesso a serviços, educação e oportunidades do dia a dia.

O desafio da comunicação reside no fato de que a Libras e a Língua Portuguesa possuem modalidades distintas, sendo Libras visual-espacial e simultânea, e a outra oral-auditiva e linear (OLIZAROSKI; MOLIN, 2024). Enquanto o português organiza os elementos da frase em sequência fixa, a Libras expressa informações por meio da combinação simultânea de configurações de mão, movimentos e expressões faciais, com ordem frasal flexível que varia conforme o contexto comunicativo (QUADROS; KARNOPP, 2004).

Com a evolução das tecnologias em inteligência artificial, surgem novas maneiras de diminuir essas barreiras. A proposta do trabalho apoia-se em quatro eixos tecnológicos complementares.

O primeiro eixo é a visão computacional, responsável por capturar e interpretar os sinais a partir do fluxo de vídeo da câmera. Nesse processo, a ferramenta MediaPipe (LUGARESI et al., 2019) desempenha o papel central ao detectar, com o processamento ao vivo, os 21 pontos-chave (*landmarks*) das articulações de cada mão e os 468 marcos faciais, fornecendo coordenadas tridimensionais que descrevem a geometria e o movimento dos sinais de forma compacta e independente de variações de iluminação ou tom de pele (ZHANG et al., 2020).

O segundo eixo é o aprendizado profundo (*deep learning*), que fornece a base para o reconhecimento dos sinais a partir dessas representações visuais. Para sinais estáticos, como as configurações do alfabeto manual, são empregadas Redes Neurais Convolucionais (CNN), capazes de identificar padrões espaciais nas configurações de mão (LECUN et al., 1998). Para sinais dinâmicos, cuja compreensão depende da trajetória e da sequência de movimentos ao longo do tempo, utilizam-se Redes de Memória de Longo Prazo (LSTM), arquitetura especializada no processamento de sequências temporais (HOCHREITER; SCHMIDHUBER, 1997).

O terceiro eixo é o processamento de linguagem natural (NLP), que atua como uma camada de conversão inteligente entre as saídas do reconhecedor de gestos e o texto intermediário em português. Sua função é interpretar os sinais isolados identificados pela visão computacional e reorganizá-los semanticamente e sintaticamente, realizando os ajustes de concordância e ordem frasal necessários para transformar a estrutura própria da Libras em frases coerentes e gramaticalmente corretas. Para isso, o módulo de NLP, implementado com a biblioteca spaCy, utiliza árvores de dependência sintática para identificar as relações gramaticais entre os *tokens* (sujeito, verbo e objeto) e reconstituir a sentença na estrutura

do português (JURAFSKY; MARTIN, 2023).

O quarto eixo é o uso de um Modelo de Linguagem de Grande Escala (LLM, do inglês *Large Language Model*), responsável por refinar e contextualizar a saída produzida pelo módulo de NLP. Após a reorganização sintática inicial, o LLM recebe a frase intermediária e aplica conhecimento linguístico profundo para corrigir ambiguidades, inserir artigos e preposições ausentes e produzir uma sentença final fluente em português (BROWN et al., 2020). Essa camada agrega robustez ao sistema, tratando casos em que regras determinísticas de NLP seriam insuficientes para capturar nuances da comunicação natural.

O sistema será treinado e validado sobre três *datasets* de Libras: o MINDS-Libras (REZENDE, 2021), o V-Librasil (RODRIGUES, 2021) e o Libras Brazilian Sign Language (PAS, 2020), selecionados pela diversidade de sinalizadores, vocabulário e modalidade de captura. O desempenho da solução será avaliado por métricas: a acurácia e a matriz de confusão para o módulo de reconhecimento gestual, a métrica BLEU (PAPINENI et al., 2002) para a qualidade linguística das traduções geradas, a validação feita por usuários reais e a latência para verificar a adequação do sistema ao uso em tempo de execução.

Com o objetivo de contribuir para a inclusão social através de uma solução acessível em atendimentos, ambientes educacionais e interações cotidianas, este trabalho propõe um sistema integrado de tradução de Libras que articula visão computacional, deep learning, processamento de linguagem natural e modelos de linguagem de grande escala. Devido à amplitude lexical da língua e à natureza experimental do estudo, a pesquisa delimita-se, inicialmente, ao reconhecimento de um conjunto específico de sinais. Essa delimitação garante o rigor técnico na integração dos eixos, estabelecendo um modelo de referência para futuras expansões do léxico.

1.1 Contexto

A comunicação é necessária para a integração social e o exercício da cidadania. Contudo, para a comunidade surda no Brasil, essa interação muitas vezes é limitada por barreiras linguísticas significativas.

Conforme dados da Pesquisa Nacional de Saúde do IBGE (2019), o Brasil conta com mais de 10,7 milhões de pessoas com cinco anos ou mais de idade que referiram alguma dificuldade auditiva irreversível, das quais aproximadamente 2,3 milhões declararam ter muita dificuldade ou não conseguir ouvir de modo algum.

Desse contingente populacional, chama a atenção o fato de que em cerca 284 mil dominam a Língua Brasileira de Sinais, evidenciando o abismo comunicacional existente. O panorama detalhado desse cenário estatístico, que cruza o grau de limitação auditiva com o conhecimento de Libras, está sintetizado na Tabela 1.

Tabela 1 – População de 5 anos ou mais com dificuldade permanente para ouvir por conhecimento de Libras (Brasil, 2019).

Grau de dificuldade para ouvir	Total (Pessoas)	Sabe usar Libras	Não sabe usar Libras
Total	10.787.458	284.138	10.503.319
Alguma dificuldade	8.462.304	149.364	8.312.939
Muita dificuldade	2.127.560	64.043	2.063.517
Não consegue ouvir de modo algum	197.594	70.731	126.863

Fonte: Adaptado de IBGE - Pesquisa Nacional de Saúde (Tabela 8223).

1.2 Justificativa

A comunicação é fundamental para a inclusão social e para a participação das pessoas na sociedade. No Brasil, embora a Língua Brasileira de Sinais (Libras) seja reconhecida oficialmente, ainda existem dificuldades na comunicação entre pessoas surdas e ouvintes. Um dos principais motivos é o número reduzido de pessoas que conhecem a língua, o que acaba limitando interações no dia a dia. Diante disso, torna-se importante pensar em alternativas que utilizem tecnologia para facilitar essa comunicação e tornar o acesso mais inclusivo.

Do ponto de vista acadêmico, este trabalho se insere na área de Ciência da Computação ao combinar técnicas de visão computacional e processamento de linguagem natural em uma mesma solução. Trata-se de um problema envolve desde o reconhecimento de movimentos e gestos até a construção de frases compreensíveis em português. Além disso, lidar com dados visuais em sequência e interpretar corretamente os sinais são desafios relevantes, o que torna a proposta interessante como estudo e desenvolvimento na área de inteligência artificial aplicada.

Em relação à prática, a proposta pode trazer benefícios concretos, principalmente para a comunidade surda. Um sistema capaz de traduzir Libras pode ajudar a diminuir a dependência de intérpretes em situações cotidianas, como atendimentos, ambientes educacionais ou interações básicas. Com isso, há um ganho em autonomia e acessibilidade, além de ampliar as possibilidades de comunicação em diferentes contextos.

Apesar de já existirem pesquisas nessa área, ainda há aspectos que podem ser melhor explorados. Muitos trabalhos focam no reconhecimento de sinais isolados, sem considerar de forma mais ampla o contexto da comunicação. Além disso, ainda são limitados os estudos que integram todo o processo, desde a identificação dos gestos até a formação de frases com sentido em português.

Portanto, este trabalho busca avançar nesse quesito ao propor uma solução mais integrada, que não se limite apenas ao reconhecimento individual de sinais, mas que também considere a construção da linguagem. A intenção é contribuir tanto para a área acadêmica quanto para a sociedade, explorando uma aplicação prática da inteligência

artificial voltada à acessibilidade.

1.3 Hipótese

A utilização de uma arquitetura híbrida baseada em CNN, LSTM, NLP e LLM viabiliza a tradução de sinais estáticos e dinâmicos da Libras para o português. A eficiência do sistema sustenta-se na hipótese de que os modelos de aprendizado profundo alcançarão acurácia adequada na identificação geométrica e temporal dos gestos, enquanto a integração sequencial dos módulos de NLP e LLM fornecerá fluência textual robusta, gerando sentenças coerentes, semanticamente refinadas e com baixa latência para aplicação em contextos reais de interação social.

1.4 Objetivo

Os objetivos deste trabalho estão voltados para o desenvolvimento de uma solução capaz de auxiliar na comunicação entre pessoas surdas e ouvintes por meio da tradução de Libras. Para isso, define-se um objetivo principal que orienta a proposta geral do sistema, enquanto os objetivos secundários detalham as etapas necessárias para sua construção, incluindo desde o levantamento bibliográfico até a implementação e avaliação da solução.

1.4.1 Objetivo principal

Implementar um sistema computacional capaz de reconhecer sinais da Língua Brasileira de Sinais (Libras) por meio de visão computacional e traduzi-los em frases gramaticalmente coerentes em língua portuguesa, utilizando técnicas de processamento de linguagem natural e modelos de linguagem de grande escala.

1.4.2 Objetivos secundários

1. Realizar levantamento bibliográfico sobre reconhecimento de gestos em Libras, arquiteturas de redes neurais convolucionais e recorrentes, processamento de linguagem natural e modelos de linguagem de grande escala aplicados à tradução;
2. Selecionar, estruturar e pré-processar os datasets de Libras, aplicando técnicas de divisão de dados, augmentação, SMOTE e ponderação de classes para garantir a qualidade do treinamento;
3. Projetar a arquitetura híbrida do sistema, integrando o módulo de visão computacional baseado em MediaPipe, CNN e LSTM ao módulo de NLP implementado com spaCy e refinamento via LLM;

4. Implementar um protótipo funcional do pipeline completo de tradução, desde a captura de vídeo via câmera até a exibição da frase traduzida em português na interface do usuário;
5. Validar o desempenho do sistema por meio de métricas quantitativas de acurácia e matriz de confusão para o módulo de reconhecimento gestual, métrica BLEU para a qualidade linguística das traduções, e análise de latência para verificar a viabilidade do uso em tempo de execução.

2 Revisão Bibliográfica

Neste capítulo, são apresentados os conceitos fundamentais necessários para o entendimento do problema. Inicialmente, são abordadas as diferenças estruturais entre a Língua Brasileira de Sinais (Libras) e a Língua Portuguesa. Em seguida, são apresentados os fundamentos de visão computacional aplicados ao reconhecimento de gestos e o uso de redes neurais. Por fim, são discutidos conceitos de processamento de linguagem natural e modelos de linguagem em grande escala, que servirão como base para a construção de frases em português a partir dos sinais identificados.

2.1 Referencial teórico

De acordo com a [República \(2005\)](#), Língua Brasileira de Sinais (Libras) é uma língua natural, completa e autônoma, utilizada pela comunidade surda no Brasil, reconhecida pela Lei nº 10.436/2002 e regulamentada pelo Decreto nº 5.626/2005 como meio legal de comunicação e expressão. Possui estrutura gramatical própria, independente da Língua Portuguesa, e está inserida em um contexto cultural e linguístico específico da comunidade surda.

Do ponto de vista linguístico, a Libras pertence à modalidade visual-espacial, caracterizando-se pela capacidade de expressar múltiplos blocos de informação simultaneamente por meio da combinação de sinais, movimentos e expressões faciais. Esse modelo contrapõe-se diretamente à modalidade oral-auditiva da língua portuguesa, cuja estrutura é essencialmente linear e baseada na organização de elementos em uma sequência fonética e temporal fixa.

As expressões faciais e corporais possuem papel fundamental na Libras, não sendo utilizadas apenas para transmitir emoções, mas também como elementos gramaticais da língua. Conhecidas como Expressões Não Manuais (ENM), elas complementam os sinais realizados com as mãos e auxiliam na construção do significado das frases ([QUADROS; KARNOPP, 2004](#)). Em muitos casos, a ausência dessas expressões pode dificultar a compreensão ou até alterar o sentido do enunciado.

Diferentes movimentos do rosto podem indicar intenções comunicativas específicas. Expressões faciais associadas ao movimento das sobrancelhas, por exemplo, podem marcar perguntas, negações e intensificações, funcionando como elementos linguísticos da estrutura da Libras ([BRITO, 1995](#)). Além disso, movimentos da boca, direção do olhar e expressões corporais também contribuem para a construção da mensagem e para a fluidez da comunicação.

Estudos mostram que as línguas de sinais possuem as mesmas propriedades das línguas naturais, como criatividade, organização por regras e capacidade de expressar qualquer tipo de conteúdo ([QUADROS; KARNOPP, 2004](#)).



Figura 1 – Parâmetros de formação do sinal na Libras.

Fonte: [Felipe \(2013\)](#).

No nível fonológico, os sinais são formados por parâmetros básicos, conforme detalhado na Figura 1: a configuração de mão (CM), o movimento (M), a locação (L), a orientação (Or) e as expressões não manuais (ENM). A combinação desses elementos forma os sinais, e mudanças em qualquer um desses parâmetros podem alterar o significado.

Do ponto de vista morfológico, a Libras apresenta uma estrutura diferente da língua portuguesa. Em vez de adicionar partes de forma sequencial (como prefixos e sufixos), os elementos do sinal são combinados ao mesmo tempo. Por exemplo, informações como número, negação e até mesmo o objeto da ação podem ser incorporadas diretamente ao sinal. Além disso, a relação entre o sujeito e o objeto da ação pode ser indicada pela direcionalidade do movimento, que conecta os pontos de referência criados durante a comunicação.

No nível sintático, a língua portuguesa segue predominantemente a ordem Sujeito-Verbo-Objeto (SVO). Já a Libras apresenta maior flexibilidade, sendo possíveis diferentes organizações, como SVO, SOV, OSV e VOS, dependendo do contexto. Isso ocorre porque a língua utiliza o espaço para indicar relações entre os elementos da frase, reduzindo a necessidade de uma ordem fixa.

Para demonstrar a flexibilidade sintática da Libras e como ela contrasta com a estrutura linear do português, considera-se a sentença composta pelos tokens sinalizados [VOCÊ, QUERER, ÁGUA] ([LOPEZ; KALITA, 2017](#)). Enquanto na língua portuguesa o enunciado possui uma organização predominantemente fixa, na Libras a ordem varia conforme o foco e o contexto comunicativo ([QUADROS; KARNOPP, 2004](#)).

A Tabela 2 ilustra como o pipeline de Processamento de Linguagem Natural (NLP) mapeia os componentes de Sujeito (S), Verbo (V) e Objeto (O) sob quatro tipologias frasais distintas, executando a função de reordenação π necessária para convergir na estrutura alvo unificada do português.

Tabela 2 – Mapeamento estrutural das variações frasais da Libras para o Português (SVO).

Tipologia	Sequência de Tokens (Libras)	Componentes
SVO	[VOCÊ] [QUERER] [ÁGUA]	Sujeito + Verbo + Objeto
SOV	[VOCÊ] [ÁGUA] [QUERER]	Sujeito + Objeto + Verbo
OSV	[ÁGUA] [VOCÊ] [QUERER]	Objeto + Sujeito + Verbo
VOS	[QUERER] [ÁGUA] [VOCÊ]	Verbo + Objeto + Sujeito

Fonte: Autoria própria (2026), baseado em [Quadros e Karnopp \(2004\)](#) e [Jurafsky e Martin \(2023\)](#).

Essas diferenças impactam diretamente o processo de tradução. Elementos comuns no português, como artigos e preposições, nem sempre aparecem de forma explícita na Libras, pois muitas dessas relações são expressas pelo uso do espaço e pelo contexto. Por isso, sistemas computacionais precisam não apenas reconhecer os sinais, mas também reorganizar as informações e incluir elementos necessários para gerar frases corretas em português.

2.2 Metodologia da pesquisa bibliográfica

A pesquisa bibliográfica foi realizada nas bases Google Scholar, utilizando as seguintes palavras-chave em português e inglês: “*Libras*” AND “*Deep Learning*” AND “*Visão Computacional*”, “*Reconhecimento de sinais*” AND “*Libras*” AND (“*CNN*” OR “*LSTM*”) e “*Língua Brasileira de Sinais*” AND “*Acessibilidade*” AND “*Redes Neurais*”.

Foram selecionados artigos publicados entre 2021 e 2026, em português e inglês, que abordassem diretamente o reconhecimento automático de sinais, técnicas de visão computacional aplicadas à Libras e métodos de processamento de linguagem natural voltados à tradução de linguagem de sinais.

A seleção dos estudos seguiu o processo de *Screening* em dois estágios sequenciais. No primeiro estágio, realizou-se a triagem por título e resumo, eliminando produções claramente fora do escopo temático. No segundo estágio, procedeu-se à leitura do texto completo dos artigos pré-selecionados, aplicando os critérios de inclusão e exclusão definidos a seguir, o que resultou no conjunto de trabalhos analisados.

Os critérios de inclusão adotados foram: (i) publicações no período de 2021 a 2026; (ii) artigos em português ou inglês; (iii) trabalhos que utilizassem técnicas de visão computacional, redes neurais (CNN, LSTM ou similares) ou processamento de linguagem natural aplicados ao reconhecimento ou à tradução de línguas de sinais; e (iv) estudos com avaliação quantitativa de desempenho.

Os critérios de exclusão foram: (i) publicações anteriores a 2021; (ii) artigos sem relação direta com línguas de sinais ou acessibilidade para surdos; (iii) trabalhos sem metodologia técnica reproduzível, como editoriais e resumos de conferência sem detalhamento experimental; e (iv) estudos sem acesso ao texto completo nas bases consultadas.

O fluxo de filtragem decorrente da aplicação desses critérios, desde o volume inicial de produções encontradas até o conjunto de artigos selecionados para análise, está sistematizado no funil metodológico apresentado na Figura 2.




Figura 2 – Funil metodológico da seleção e filtragem da pesquisa bibliográfica.

Autoria própria (2026).

2.3 Fundamentos

Este tópico apresenta os principais fundamentos teóricos e tecnológicos que sustentam o desenvolvimento do sistema proposto. Inicialmente, estabelece-se o panorama macro através dos conceitos de Inteligência Artificial e *Machine Learning*, delimitando o paradigma computacional adotado. Em seguida, são abordados os conceitos de visão computacional, MediaPipe e landmarks, responsáveis pela captura e representação dos sinais em Libras. Posteriormente, detalha-se o universo do *Deep Learning*, incluindo o funcionamento de redes CNN e redes LSTM, aplicadas no reconhecimento de sinais estáticos e dinâmicos. Por fim, são discutidos os conceitos de Processamento de Linguagem Natural (NLP), as árvores de dependência sintática, os Modelos de Linguagem de Grande Escala (LLM) e as métricas de avaliação empregadas no sistema.

2.3.1 Inteligência Artificial (IA)

A Inteligência Artificial (IA) é um campo da Ciência da Computação dedicado ao desenvolvimento de sistemas capazes de executar tarefas que normalmente requerem inteligência humana, como percepção, raciocínio, aprendizado e tomada de decisão (RUSSELL; NORVIG, 2021). Seu objetivo é criar métodos computacionais capazes de interpretar informações do ambiente, extrair conhecimento a partir de dados e agir de forma autônoma para alcançar determinados objetivos.

Antigamente, os sistemas de Inteligência Artificial não aprendiam sozinhos: eles apenas seguiam regras e instruções fixas criadas e programadas por humanos. Com o aumento da

disponibilidade de dados e do poder computacional, surgiram técnicas capazes de aprender padrões diretamente a partir de exemplos, consolidando o paradigma conhecido como *Machine Learning* (IBM, 2026).

Atualmente, a Inteligência Artificial engloba diversas áreas de pesquisa e aplicação, incluindo aprendizado de máquina, visão computacional, processamento de linguagem natural, robótica e sistemas de recomendação. Essas áreas compartilham o objetivo comum de permitir que sistemas computacionais interpretem informações complexas e realizem tarefas que anteriormente dependiam exclusivamente da capacidade humana (RUSSELL; NORVIG, 2021).

No contexto deste trabalho, a Inteligência Artificial constitui o campo teórico que fundamenta o desenvolvimento da solução proposta, fornecendo os conceitos e técnicas que possibilitam o reconhecimento de padrões visuais e o processamento computacional da linguagem necessários para a tradução da Libras para a língua portuguesa.

2.3.2 Machine Learning

O Aprendizado de Máquina (*Machine Learning*, ML) é uma subárea da Inteligência Artificial dedicada ao desenvolvimento de algoritmos capazes de aprender padrões a partir de dados e utilizá-los para realizar previsões, classificações ou tomadas de decisão sem que todas as regras precisem ser explicitamente programadas (MITCHELL, 1997; FACELI et al., 2021). Em vez de depender exclusivamente de instruções definidas por um programador, os modelos ajustam seus parâmetros com base em exemplos durante o processo de treinamento.

Os métodos de Aprendizado de Máquina são tradicionalmente classificados em três categorias principais (GÉRON, 2022; CHEN, 2024):

- **Aprendizado Supervisionado:** utiliza conjuntos de dados rotulados, nos quais cada exemplo de entrada está associado a uma saída esperada. O objetivo é aprender uma função capaz de realizar previsões corretas para novos dados;
- **Aprendizado Não Supervisionado:** trabalha com dados sem rótulos, buscando identificar padrões, agrupamentos ou estruturas ocultas presentes nas informações analisadas;
- **Aprendizado por Reforço:** baseia-se na interação entre um agente e um ambiente, onde o aprendizado ocorre por meio de recompensas e penalidades associadas às ações executadas.

O avanço do *Machine Learning* impulsionou o desenvolvimento de aplicações em diversas áreas, incluindo reconhecimento de imagens, processamento de linguagem natural, sistemas de recomendação e análise preditiva (FACELI et al., 2021). Entre suas vertentes,

destaca-se o *Deep Learning*, que utiliza redes neurais com múltiplas camadas para modelar problemas complexos a partir de grandes volumes de dados.

No contexto deste trabalho, o Aprendizado de Máquina fornece a base para o treinamento dos modelos responsáveis pelo reconhecimento dos sinais da Libras. A partir de exemplos previamente rotulados, os algoritmos aprendem a associar padrões extraídos dos landmarks das mãos e do rosto às respectivas classes de sinais, possibilitando a identificação automática dos gestos realizados pelo usuário.

2.3.3 Datasets

No desenvolvimento de modelos de *Deep Learning*, o dataset (base de dados) constitui o pilar fundamental para o treinamento e a validação do sistema. Segundo [Schmidhuber \(2014\)](#), a eficácia de arquiteturas complexas como CNNs e LSTMs depende diretamente da disponibilidade de grandes volumes de dados rotulados, que permitem ao modelo aprender representações estatísticas precisas e generalizáveis.

No contexto do reconhecimento de Libras, os datasets apresentam desafios devido à natureza multimodal da língua. Um *dataset* robusto para este fim deve conter não apenas imagens isoladas, mas sequências de vídeo que capturem a dinâmica dos sinais. De acordo com [Silva \(2017\)](#), a diversidade dos dados é crucial para mitigar problemas de overfitting, ou seja, a perda de capacidade de generalização do sistema por memorização exaustiva dos dados de treinamento, garantindo que o sistema seja capaz de reconhecer gestos realizados por diferentes usuários, com variações em:

- Antropometria: Diferenças no tamanho, cor, formato das mãos e traços faciais dos sinalizadores;
- Condições Ambientais: Variações de iluminação e fundos de imagem (backgrounds) complexos, que testam a capacidade de segmentação do modelo;
- Execução do Sinal: Diferenças na velocidade, amplitude e fluidez do movimento, que impactam diretamente a análise temporal das redes LSTM.

Os três datasets adotados neste projeto apresentam diversidade de dados a esse respeito: o MINDS-Libras conta com distribuição controlada, são 6 pessoas realizando 5 repetições de cada um dos 20 sinais, resultando em classes uniformes ([REZENDE, 2021](#)); o V-Libras possui estrutura regular, com 3 gravações por sinal para cada um dos 1.364 termos ([RODRIGUES, 2021](#)); já o dataset Libras Brazilian Sign Language, composto por imagens estáticas do alfabeto manual, apresenta variação no número de amostras entre as classes, característica comum em datasets tratados a partir de fontes variadas ([PAS, 2020](#)).

Além disso, a estruturação do dataset deve prever a divisão entre conjuntos de treinamento, validação e teste. Conforme explicam [Goodfellow, Bengio e Courville \(2016\)](#),

essa separação é o que permite avaliar a capacidade de generalização do algoritmo frente a dados nunca vistos, assegurando que o tradutor de Libras funcione corretamente em cenários do mundo real e não apenas em ambientes controlados de laboratório.

2.3.4 Pré-processamento de Dados

Antes da aplicação dos modelos de *deep learning*, é necessária uma etapa de pré-processamento dos dados visuais, com o objetivo de melhorar a qualidade das informações fornecidas ao sistema e aumentar a precisão do reconhecimento dos sinais.

O pré-processamento envolve técnicas de tratamento de imagem, como redimensionamento dos frames, normalização dos valores de pixel e remoção de ruídos. Além disso, podem ser aplicados filtros para suavização da imagem e ajuste de contraste, reduzindo interferências causadas por variações de iluminação e fundo. Segundo Szeliski (2010), essas etapas são fundamentais para garantir que os algoritmos de visão computacional consigam extrair características relevantes de forma eficiente. Para ampliar a diversidade do conjunto de treinamento e reduzir problemas de *overfitting*, será aplicado *data augmentation* sobre os dados visuais, por meio de operações como espelhamento, rotações e variações de velocidade dos vídeos (GOODFELLOW; BENGIO; COURVILLE, 2016), conforme ilustrado na Figura 3. Essas transformações aumentam artificialmente a diversidade do conjunto de treinamento, melhorando a capacidade de generalização dos modelos.




Figura 3 – Exemplo de técnicas de *Data Augmentation* aplicadas a uma imagem original.

Fonte: Adaptado IBM Think (2025).

Outro aspecto relevante é a padronização dos dados de entrada, garantindo que todas

as imagens ou sequências possuam dimensões e formatos consistentes. Essa uniformidade é essencial para funcionamento correto das redes neurais, especialmente em modelos baseados em CNN e LSTM.

Também é importante o balanceamento de classes. Em datasets de reconhecimento de sinais, é comum que determinadas classes possuam um número de amostras significativamente maior do que outras. Quando treinado sobre dados desbalanceados, o modelo tende a favorecer as classes com maior quantidade, comprometendo o desempenho nas classes com menor representatividade (CHAWLA et al., 2002). Para mitigar esse efeito, será adotada a ponderação de classes na função de perda durante o treinamento, penalizando mais os erros cometidos nas classes menos frequentes (GOODFELLOW; BENGIO; COURVILLE, 2016).

Para consolidar a regularização estatística do pipeline, aplica-se a técnica SMOTE (*Synthetic Minority Over-sampling Technique*) sobre os vetores de *landmarks* extraídos pelo MediaPipe, gerando exemplos sintéticos por interpolação matemática entre amostras próximas no espaço de características, sem manipular diretamente os pixels brutos (?). Por fim, os dados serão divididos em conjuntos de treinamento, validação e teste, separação que, conforme explicam Goodfellow, Bengio e Courville (2016), é o que permite avaliar a capacidade de generalização do modelo frente a dados nunca vistos, assegurando que o tradutor funcione corretamente em cenários reais e não apenas em ambientes controlados de laboratório.

2.3.5 Visão Computacional

A Visão Computacional é o campo da ciência da computação que capacita máquinas a extrair informações significativas de imagens e vídeos, interpretando o meio visual de forma análoga à percepção humana (MILANO; HONORATO, 2014). Segundo Dave Bergmann (2025), enquanto a visão humana é intuitiva e imediata, as máquinas dependem de algoritmos capazes de converter pixels e dados brutos em representações estruturadas e semanticamente compreensíveis.

No contexto deste projeto, a visão computacional constitui a primeira e mais crítica etapa do pipeline de tradução, pois é responsável por transformar o fluxo de vídeo capturado pela câmera em vetores de características numéricas que alimentam os modelos de reconhecimento. Essa transformação ocorre em quatro etapas sequenciais, descritas a seguir e sintetizadas na Figura 4.

1. A primeira etapa é a captura de frames, em que o vídeo proveniente da webcam é segmentado em quadros individuais para processamento em tempo real.
2. A segunda etapa é a detecção de mãos e rosto, na qual o framework MediaPipe analisa cada frame para localizar e isolar as regiões de interesse, os membros superiores e a face, do restante da cena. De acordo com Neves, Neto e Gonzaga (2012), essa etapa

é fundamental para garantir que o sistema concentre a análise exclusivamente nas regiões que carregam informação linguística.

3. A terceira etapa é a extração de landmarks, em que o MediaPipe mapeia as coordenadas tridimensionais (x, y, z) dos 21 pontos articulares de cada mão e dos 468 pontos-chave do rosto, produzindo uma representação geométrica compacta e invariante a variações de iluminação e tom de pele (ZHANG et al., 2020).
4. A quarta etapa é a classificação do sinal, na qual os vetores de landmarks são encaminhados ao módulo de aprendizado profundo: sinais estáticos são processados pela CNN, que analisa a configuração espacial da mão em um único frame, enquanto sinais dinâmicos são processados pela LSTM, que modela a sequência temporal de landmarks ao longo do movimento. Conforme explicam Pinho, Tavares e Correia (2004), é justamente essa capacidade de distinguir configurações estáticas de padrões de movimento que permite identificar os diferentes elementos do léxico da Libras.



Figura 4 – Pipeline da Visão Computacional.

Autoria própria (2026).

2.3.6 MediaPipe & Landmarks

O *MediaPipe* é um *framework* de código aberto desenvolvido pelo *Google* para a construção de pipelines de percepção multimodal em tempo real (LUGARESI et al., 2019). Ele disponibiliza soluções pré-treinadas para tarefas de visão computacional, incluindo detecção de pose corporal, rastreamento de mãos e rastreamento facial. No contexto deste trabalho, destacam-se os módulos *MediaPipe Hands* e *MediaPipe Face Mesh*, utilizados para extrair os *landmarks* das mãos e do rosto que servirão como entrada para os modelos de reconhecimento dos sinais da Libras.

Os *landmarks*, ou pontos-chave, são as coordenadas tridimensionais (x, y, z) extraídas por essas soluções de partes anatomicamente relevantes do corpo, articulações das mãos e regiões do rosto, utilizadas para representar a geometria e o movimento dos sinais de forma compacta e independente de variações de iluminação ou tom de pele (ZHANG et al., 2020).

A solução *MediaPipe Hands* opera em dois estágios sequenciais (ZHANG et al., 2020). No primeiro, um detector leve baseado em *deep learning* localiza a palma da mão na imagem completa, produzindo um *bounding box* delimitador. No segundo, um modelo de

regressão de *landmarks* recebe o recorte da mão e estima as coordenadas tridimensionais (x, y, z) de 21 pontos-chave que representam as articulações dos dedos e o pulso, conforme ilustrado na Figura 5. As coordenadas x e y são normalizadas em relação às dimensões do *frame* (valores entre 0 e 1), enquanto z representa a profundidade relativa ao pulso, permitindo inferir a orientação tridimensional da mão mesmo com uma câmera RGB comum (ZHANG et al., 2020).




Figura 5 – Esquema dos 21 *landmarks* detectados pelo *MediaPipe Hands*.

Fonte: TensorFlow (2021).

O *MediaPipe Face Mesh*, por sua vez, mapeia 468 pontos-chave do rosto em tempo de execução, distribuídos pelas regiões de sobrancelha, olhos, bochecha e boca, conforme ilustrado na Figura 6 (LUGARESI et al., 2019). Essa cobertura é essencial para a captura das Expressões Não Manuais (ENM) da Libras, como a elevação de sobrancelhas para marcação de perguntas e a contração facial para negação, que exercem função gramatical obrigatória na língua e não podem ser ignoradas sem perda de significado (BRITO, 1995).




Figura 6 – Esquema dos 468 *landmarks* detectados pelo *MediaPipe Face Mesh*.

Fonte: [Khaleel, Abbas e Ibrahim \(2024\)](#).

No contexto deste projeto, os dois módulos operam simultaneamente sobre o mesmo frame, fornecendo ao sistema um vetor de entrada combinado que representa tanto a configuração manual quanto a expressão facial do sinalizador. Essa representação é invariante a variações de aparência física entre usuários, pois baseia-se em geometria articular e não em pixels brutos, reduzindo drasticamente a dimensionalidade dos dados e tornando o treinamento mais eficiente e generalizável ([LUGARESI et al., 2019](#)).

2.3.7 Deep Learning

O *Deep Learning*, ou Aprendizado Profundo, é uma subárea do *Machine Learning* que utiliza redes neurais artificiais com múltiplas camadas de processamento. Segundo a [Dave Bergmann \(2026\)](#), essa abordagem é inspirada na estrutura do cérebro humano, onde cada camada de "neurônios" executa operações matemáticas para aprender representações cada vez mais abstratas dos dados.

Diferente dos métodos tradicionais, o *deep learning* permite que o sistema identifique características automaticamente, sem a necessidade de intervenção humana manual. Conforme explica a [Oracle \(2022\)](#), essa capacidade de autoajuste através de pesos e vieses é o que torna os modelos extremamente precisos para resolver problemas complexos.

Um dos principais motivos para a ampla adoção desta tecnologia é o seu desempenho em tarefas que envolvem visão computacional e processamento de texto. De acordo com

Schmidhuber (2014), o aprendizado profundo revolucionou o reconhecimento de padrões ao permitir a análise de grandes volumes de dados não estruturados.

No contexto deste projeto, o uso do *deep learning* justifica-se pela necessidade de tratar informações visuais e sequenciais simultaneamente. Segundo Goodfellow, Bengio e Courville (2016), redes profundas são aproximadores universais capazes de mapear entradas complexas para saídas específicas, como a tradução de um gesto em texto.

Dessa forma, a profundidade dessas redes permite que o sistema capture desde detalhes mínimos de um frame até o contexto completo de uma frase em Libras. Conforme destacam Fleck et al. (2016), essa estrutura multicamada é essencial para que o modelo aprenda padrões que seriam invisíveis para algoritmos de aprendizado mais simples. Uma representação visual desse fluxo de informações através de múltiplas camadas pode ser observada na Figura 7.



Figura 7 – Fluxo de processamento hierárquico em uma arquitetura de Deep Learning.

Fonte: Computer Weekly (2026).

2.3.8 Redes Neurais Convolucionais (CNN)

As Redes Neurais Convolucionais (CNN) são arquiteturas de *deep learning* especializadas no processamento de dados com topologia em grade, como imagens e sequências. Introduzidas por LeCun et al. (1998) e popularizadas com o modelo AlexNet (KRIZHEVSKY; SUTSKEVER; HINTON, 2012), as CNNs revolucionaram o campo da visão computacional ao substituir a extração manual de características por um processo de aprendizado automático e hierárquico.

No escopo deste trabalho, a CNN é utilizada para o reconhecimento de sinais estáticos, como as configurações de mão do alfabeto manual da Libras, nos quais a identificação do sinal depende exclusivamente da configuração espacial da mão em um único *frame* (FLECK et al., 2016).

A arquitetura de uma CNN é composta por três tipos principais de camadas que se alternam e se combinam ao longo da rede (GOODFELLOW; BENGIO; COURVILLE, 2016):

1. Camada de Convolução: Conjunto de filtros (também chamados de *kernels*) de tamanho reduzido, tipicamente 3×3 ou 5×5 pixels, desliza sobre a imagem de entrada, calculando o produto escalar entre os pesos do filtro e os pixels da região coberta. Matematicamente, para uma imagem de entrada I e um filtro K , a operação de convolução discreta é definida como:

$$(I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n) \quad (2.1)$$

I : Imagem de entrada.

K : Filtro ou *kernel*.

(i, j) : Posição atual do pixel na saída (mapa de características).

(m, n) : Índices do *kernel*.

O resultado é chamado de mapa de ativação, que representa a presença de um determinado padrão visual (como bordas, curvas ou texturas) em cada posição espacial da imagem (GOODFELLOW; BENGIO; COURVILLE, 2016). O compartilhamento de pesos entre todas as posições da imagem reduz drasticamente o número de parâmetros treináveis e confere à CNN invariância à translação, o modelo reconhece o padrão independentemente de onde ele aparece na imagem (FLECK et al., 2016).

2. Camada de Pooling: Após a convolução, a camada de *pooling* realiza uma subamostragem espacial dos mapas de ativação, reduzindo suas dimensões e, com isso, a quantidade de parâmetros e o custo computacional das camadas subsequentes. A operação mais comum é o Max Pooling, que seleciona o valor máximo dentro de uma janela de tamanho fixo (por exemplo, 2×2), retendo as características mais proeminentes e descartando informações redundantes (LECUN et al., 1998). Esse mecanismo também contribui para a robustez do modelo a pequenas variações de posição e escala dos objetos.
3. Camadas Totalmente Conectadas: Ao final da rede, após um conjunto de camadas de convolução e *pooling*, os mapas de ativação são linearizados e alimentados em uma ou mais camadas totalmente conectadas, que funcionam como um classificador tradicional. Nessa etapa, as representações abstratas aprendidas pelas camadas anteriores são combinadas para gerar a predição final, por exemplo, a probabilidade de que o gesto capturado corresponda a cada letra do alfabeto manual (FURTADO, 2019).

A integração sequencial e o fluxo de dados entre essas três camadas fundamentais que compõem a topologia da rede estão ilustrados na Figura 8.




Figura 8 – Diagrama de blocos e fluxo de dados em uma Rede Neural Convolucional.

Fonte: [IONOS Digital Guide \(2026\)](#).

No contexto deste projeto, os *landmarks* extraídos pelo MediaPipe (coordenadas x , y , z das articulações da mão) são organizados como vetores de entrada para a CNN. A rede aprende, durante o treinamento, quais combinações de posições articulares são discriminativas para cada sinal estático.

Conforme apontam [Fleck et al. \(2016\)](#), o sucesso das CNNs em tarefas de visão computacional deve-se à sua capacidade de identificar características locais de forma hierárquica: as camadas iniciais capturam padrões simples (orientação dos dedos, curvatura das juntas) e as camadas mais profundas combinam esses padrões em representações de alto nível (configuração completa da mão). Essa configuração garante maior robustez a variações de iluminação e enquadramento ([FURTADO, 2019](#)).

2.3.9 Redes de Memória de Longo Prazo (LSTM)

Para o reconhecimento de sinais dinâmicos em vídeo, onde o significado do gesto reside no movimento ao longo do tempo, utiliza-se a Long Short-Term Memory (LSTM). Esta arquitetura é uma evolução das Redes Neurais Recorrentes (RNN) tradicionais, introduzida por [Hochreiter e Schmidhuber \(1997\)](#) para solucionar a limitação do desaparecimento do gradiente (*vanishing gradient*), que impede redes comuns de aprenderem dependências de longo prazo em sequências de dados.

O diferencial da LSTM é a sua unidade de memória interna, frequentemente chamada de célula, que permite a manutenção de informações por intervalos de tempo estendidos ([HOCHREITER; SCHMIDHUBER, 1997](#)). Essa estrutura é fundamental para o aprendizado de sequências complexas, como a linguagem de sinais, onde a predição ou classificação de um gesto depende de frames ocorridos em instantes anteriores ([BAYER et al., 2009](#)).

A arquitetura da célula da LSTM, ilustrada detalhadamente na Figura 9, é composta por três componentes principais, conhecidos como "portões" (*gates*), que controlam o fluxo de informação:




Figura 9 – Diagrama de Rede Neural LSTM.

Autoria própria (2026).

1. Portão de Esquecimento (*Forget Gate*): decide qual informação do estado anterior deve ser descartada;
2. Portão de Entrada (*Input Gate*): seleciona quais novas informações serão armazenadas no estado da célula;
3. Portão de Saída (*Output Gate*): determina qual parte do estado interno será enviada como saída para o próximo passo temporal ((CONTARINI, 2020); (ALMEIDA, 2019)).

No contexto do tradutor de Libras, essa capacidade de retenção temporal permite que o sistema compreenda que a trajetória e a transição entre as poses das mãos são tão importantes quanto a configuração isolada em um único frame (ALMEIDA, 2019). Como destacado por Schmidhuber (2014), a profundidade dessas redes em termos de passos

temporais possibilita a extração de representações abstratas que conectam movimentos manuais a conceitos semânticos complexos, garantindo maior precisão na interpretação de sinais dinâmicos.

2.3.10 Reconhecimento de Gestos (Gesture Recognition)

O reconhecimento de gestos é uma parte da visão computacional que visa identificar e interpretar movimentos ou posições do corpo humano a partir de dados visuais, transformando-os em comandos ou símbolos compreensíveis por máquinas (SILVA, 2017). No contexto da Língua Brasileira de Sinais (Libras), essa técnica é o pilar fundamental para a tradução automatizada, permitindo que a interação entre surdos e ouvintes ocorra de forma fluida através da interface homem-máquina (OSÓRIO, 2002).

Os gestos são geralmente classificados em duas categorias principais, cada uma exigindo abordagens algorítmicas distintas:

- **Estáticos (Imagem):** Referem-se à configuração ou postura da mão em um único instante. O foco recai sobre a forma, a orientação e a posição dos dedos, como ocorre na representação do alfabeto manual ou numerais em Libras (Júnior, 2019). Redes Neurais Convolucionais (CNNs) são frequentemente aplicadas para extrair padrões espaciais nessas imagens estáticas.
- **Dinâmicos (Vídeo):** Envolvem uma sequência de movimentos ao longo do tempo, onde a trajetória e a velocidade são cruciais para o significado do sinal (SILVA, 2017). Para interpretá-los, utilizam-se técnicas que consideram a continuidade temporal, como a subtração de quadros sucessivos para detecção de movimento ou o uso de grafos de ação e aprendizado de métricas para reconhecimento em tempo de execução (MONTEIRO et al., 2016).

A implementação eficaz desses sistemas enfrenta desafios significativos que podem comprometer a taxa de acerto do reconhecimento. As variações de iluminação representam um dos principais obstáculos, pois alterações na luz do ambiente modificam os valores dos pixels e dificultam a segmentação precisa da pele (OSÓRIO, 2002).

Além disso, a variabilidade entre usuários introduz complexidade, uma vez que diferentes pessoas possuem características físicas distintas e executam o mesmo sinal com velocidades e amplitudes diversas, exigindo modelos robustos e generalistas (SILVA, 2017).

Por fim, a influência do fundo da imagem (*background*) pode impactar a precisão, especialmente em cenários com muitos objetos ou cores semelhantes ao tom da pele humana, o que torna essencial o uso de filtros adaptativos ou técnicas de segmentação para isolar adequadamente as mãos e o rosto do restante da cena (MONTEIRO et al., 2016).

2.3.11 Árvore de Dependência Sintática

Uma árvore de dependência sintática é uma estrutura de dados que representa as relações gramaticais binárias e assimétricas entre os tokens de uma sentença. Diferentemente das gramáticas de constituintes (baseadas em sintagmas), a análise de dependência conecta diretamente pares de palavras: uma cabeça e um dependente, com uma etiqueta que nomeia o tipo de relação (*nsubj* para sujeito nominal, *obj* para objeto direto, *advmod* para modificador adverbial, etc.) (JURAFSKY; MARTIN, 2023).

Formalmente, dada uma sentença $s = (w_1, w_2, \dots, w_n)$, uma árvore de dependência é um grafo dirigido $G = (V, A)$ onde:

- $V = \{w_0, w_1, \dots, w_n\}$ é o conjunto de vértices (tokens mais um nó raiz artificial w_0);
- $A \subseteq V \times V \times \mathcal{R}$ é o conjunto de arcos rotulados, onde cada arco (w_i, w_j, r) indica que w_i é a cabeça de w_j com relação do tipo $r \in \mathcal{R}$;
- cada token (exceto a raiz) possui exatamente uma cabeça, garantindo a estrutura de árvore (JURAFSKY; MARTIN, 2023).

Como exemplo, considere a sentença “Você quer água.” Sua árvore de dependência teria *quer* como raiz (verbo principal), com *Você* ligado a ela pelo arco *nsubj* (sujeito nominal) e *água* pelo arco *obj* (objeto direto), conforme exemplificado na estrutura da Figura 10.




Figura 10 – Exemplo estrutural de uma árvore de análise por dependência sintática.

Autoria própria (2026).

No presente trabalho, a análise de dependência é realizada pela biblioteca spaCy (HONNIBAL et al., 2020), que implementa um analisador neural baseado em transições (*transition-based parser*). Esse analisador processa a sentença da esquerda para a direita, mantendo uma pilha e uma fila de tokens, e a cada passo aplica uma das três operações possíveis: *SHIFT* (empilha o próximo token), *LEFT-ARC* (cria um arco da cabeça para o dependente à esquerda) ou *RIGHT-ARC* (cria um arco da cabeça para o dependente à

direita). A escolha da operação é feita por um classificador neural que considera o contexto da pilha e da fila (HONNIBAL et al., 2020).

A adoção de árvores de dependência é especialmente adequada para este projeto por três razões. Primeiro, como a Libras apresenta ordem frasal flexível (SVO, SOV, OSV, entre outras), a análise de dependência é robusta a variações de ordem, pois identifica as relações semânticas independentemente da posição linear dos tokens (JURAFSKY; MARTIN, 2023). Segundo, a estrutura arbórea explicita quais tokens são sujeito, objeto e predicado, fornecendo ao módulo de reordenação a informação necessária para reconstruir a sentença na estrutura SVO do português. Terceiro, as etiquetas de dependência permitem aplicar regras de concordância dirigidas: identificado o sujeito (*nsubj*), é possível flexionar o verbo-cabeça no número e pessoa correspondentes (BIRD; KLEIN; LOPER, 2009).

Dessa forma, as árvores de dependência atuam como a representação intermediária que conecta a saída do reconhecedor de gestos (sequência de tokens na ordem da Libras) à frase final gramaticalmente correta em português, tornando o pipeline de tradução mais explícito, interpretável e extensível.

2.3.12 Processamento de Linguagem Natural (NLP)

O Processamento de Linguagem Natural é uma vertente da Inteligência Artificial que visa capacitar sistemas computacionais a compreender, interpretar e gerar a linguagem humana em formato de texto. Segundo Cole Stryker and Jim Holdsworth (2024), o NLP combina a linguística estatística e computacional com modelos de *deep learning* para processar a linguagem em formas que exibam compreensão de significado e intenção.

No escopo deste projeto, o reconhecimento isolado de gestos por meio de visão computacional não é suficiente para uma comunicação fluida, dada a profunda divergência gramatical entre a Libras e a língua portuguesa. Conforme apontam Lopez e Kalita (2017), o uso de redes neurais aplicadas ao NLP permite que o sistema lide com a ambiguidade inerente à linguagem e aprenda representações hierárquicas dos dados textuais. O módulo de NLP atua, portanto, como uma camada de pós-processamento essencial, realizando a conversão semântica e sintática dos sinais identificados pela rede neural.

A abordagem adotada neste trabalho baseia-se em um pipeline de processamento sequencial implementado com a biblioteca spaCy (HONNIBAL et al., 2020). Conforme ilustrado no diagrama da Figura 11, este fluxo é composto por 4 etapas fundamentais: tokenização e normalização, etiquetagem morfofossintática, análise de dependência sintática e, por fim, reordenação sintática e concordância.




Figura 11 – Diagrama de Processamento de Linguagem Natural - NLP.

Autoria própria (2026).

Os sinais identificados pela etapa de visão computacional chegam ao módulo de NLP como uma sequência de *tokens*, palavras isoladas na estrutura da Libras (ex.: [VOCÊ, QUERER, ÁGUA]). A tokenização consiste em tratar cada sinal como uma unidade lexical discreta, e a normalização realiza a lematização de cada token, reduzindo as formas flexionadas à forma canônica (lema), o que facilita o mapeamento para o português (BIRD; KLEIN; LOPER, 2009).

Cada token recebe uma etiqueta morfossintática (substantivo, verbo, pronome, etc.). No spaCy, esse processo é realizado por um modelo de rede neural treinado sobre corpora anotados (HONNIBAL et al., 2020). Formalmente, dado um vocabulário $\mathcal{V}$ e um conjunto de etiquetas $\mathcal{T}$, o *tagger* aprende uma função $f : \mathcal{V}^n \rightarrow \mathcal{T}^n$ que maximiza a probabilidade conjunta da sequência de etiquetas dado o contexto da sentença.

Após a etiquetagem, o analisador de dependências identifica as relações gramaticais entre os tokens (sujeito, objeto, modificador, etc.), produzindo uma árvore de dependência sintática.

Com base nas relações identificadas pela árvore de dependência, o módulo reordena os tokens segundo a estrutura SVO do português e aplica regras de concordância nominal e verbal. Por exemplo, a sequência da Libras [VOCÊ, QUERER, ÁGUA] é reescrita como “*Você quer água.*”, com a flexão verbal adequada ao sujeito identificado (LOPEZ; KALITA, 2017).

Formalmente, seja $S_L = (w_1, w_2, \dots, w_n)$ a sequência de sinais identificados na estrutura da Libras e S_P a frase-alvo em português. O módulo de NLP aprende uma função de reordenação π tal que:

$$S_P = \text{Flexão}(\pi(S_L), G_{\text{pt}}) \quad (2.2)$$

onde π é uma permutação dos índices dos tokens guiada pelas relações de dependência e G_{pt} representa as regras gramaticais do português, incluindo concordância de gênero, número e tempo verbal (BIRD; KLEIN; LOPER, 2009).

2.3.13 Modelos de Linguagem de Grande Escala (LLM)

Os Modelos de Linguagem de Grande Escala (LLMs, do inglês Large Language Models) são sistemas de inteligência artificial treinados em vastos volumes de dados, especializados na compreensão e geração de texto com alta fluência. Diferente das arquiteturas de *deep learning* voltadas para o processamento de sequências de dados brutos, os LLMs baseiam-se na arquitetura Transformer (VASWANI et al., 2017) para realizar o processamento semântico avançado da linguagem escrita.

No fluxo de tradução proposto, o LLM atua como uma camada de refinamento linguístico final. Após o módulo de NLP (spaCy) organizar a estrutura sintática básica e realizar as flexões necessárias, o LLM recebe essa sentença intermediária para otimizar sua naturalidade. Essa etapa é essencial para ajustar nuances que as regras gramaticais rígidas podem não captar, como a inserção de conectivos contextuais ou o ajuste de registro (formal ou informal), garantindo que a saída em português não seja apenas gramaticalmente correta, mas também fluida para o ouvinte.

A integração de modelos como Llama (TOUVRON et al., 2023) ou Gemma (Gemma Team et al., 2024) permite que o sistema aproveite a capacidade de few-shot learning (BROWN et al., 2020), ou seja, a habilidade do modelo em refinar traduções a partir de poucos exemplos de contexto, sem a necessidade de um novo treinamento exaustivo. Assim, o projeto estabelece uma arquitetura híbrida e colaborativa.

2.3.14 Custo Computacional e Peso dos Modelos

O custo computacional refere-se à quantidade de recursos necessários para executar um modelo, incluindo uso de memória, processamento e capacidade de armazenamento. Já o peso do modelo está relacionado ao número de parâmetros treináveis presentes na rede neural, influenciando diretamente seu tamanho e complexidade.

Modelos mais complexos, como redes profundas com múltiplas camadas, tendem a apresentar maior precisão, porém demandam mais recursos computacionais. Conforme discutido por Goodfellow, Bengio e Courville (2016), o aumento da profundidade das redes neurais eleva sua capacidade de representação, mas também implica maior custo de processamento e necessidade de hardware mais robusto.

No contexto deste trabalho, a escolha das arquiteturas busca equilibrar desempenho e eficiência, considerando a necessidade de processamento em tempo execução. Estratégias como o uso de *landmarks*, redução de dimensionalidade dos dados e limitação do vocabulário contribuem para diminuir o custo computacional.

Esse equilíbrio é fundamental para garantir que o sistema seja não apenas preciso, mas também utilizável em cenários práticos.

2.3.15 Acurácia & Precisão

A acurácia é uma métrica que expressa a proporção de predições corretas em relação ao total de exemplos avaliados, oferecendo uma visão geral do desempenho do sistema (GOODFELLOW; BENGIO; COURVILLE, 2016). Apesar de sua interpretação direta, a acurácia isolada pode ser insuficiente em contextos com muitas classes, pois não revela quais sinais estão sendo confundidos entre si, informação essencial para o refinamento do modelo.

Para suprir essa limitação, utiliza-se a matriz de confusão, uma representação tabular que cruza as classes reais com as classes preditas. Cada célula indica quantas amostras de uma determinada classe foram classificadas como outra, permitindo identificar padrões de erro específicos. Por exemplo, quais pares de sinais o modelo tende a confundir com maior frequência devido à semelhança na configuração de mão ou no movimento (GOODFELLOW; BENGIO; COURVILLE, 2016). A partir dela, derivam-se ainda métricas complementares como precisão e *recall*, que expõem desequilíbrios de desempenho entre as classes de forma mais granular.

A estrutura básica de uma matriz de confusão pode ser observada na Figura 12. Nela, os resultados de classificação são organizados em verdadeiros positivos (VP), verdadeiros negativos (VN), falsos positivos (FP) e falsos negativos (FN), permitindo uma análise detalhada dos acertos e erros cometidos pelo modelo durante o processo de classificação.

		Detectada	
		Sim	Não
Real	Sim	Verdadeiro Positivo (VP)	Falso Negativo (FN)
	Não	Falso Positivo (FP)	Verdadeiro Negativo (VN)

Figura 12 – Estrutura conceitual de uma matriz de confusão.

Fonte: Adaptado de Nogare (2020).

No escopo desta pesquisa, a acurácia e a matriz de confusão serão utilizadas para avaliar o módulo de visão computacional, tanto na classificação de sinais estáticos pela CNN quanto no reconhecimento de sinais dinâmicos pela LSTM. A análise conjunta dessas métricas permitirá identificar os sinais com maior taxa de erro e orientar ajustes no modelo ou na composição do dataset de treinamento.

Com essa abordagem, busca-se garantir que o sistema apresente desempenho equilibrado entre todos os sinais do vocabulário definido, e não apenas nas classes mais frequentes.

2.3.16 Métrica BLEU

A métrica BLEU (*Bilingual Evaluation Understudy*), proposta por Papineni et al. (2002), é o padrão consolidado para avaliação automática de qualidade em sistemas de tradução. Ela compara o texto gerado pelo sistema com traduções humanas de referência, mensurando a sobreposição de sequências de palavras conhecidas como n -gramas. Esses elementos representam agrupamentos contínuos de n itens; enquanto os unigramas ($n = 1$) avaliam a presença de palavras isoladas, os bigramas ($n = 2$) e trigramas ($n = 3$) permitem verificar se a ordem e o contexto gramatical foram preservados. Quanto maior a correspondência com as referências humanas, mais alto o escore BLEU, que varia de 0 a 1.

O uso do BLEU é especialmente relevante neste projeto porque o pipeline de pós-processamento, que integra o módulo de NLP e o refinamento via LLM, não apenas transcreve sinais isolados, mas reorganiza, flexiona e contextualiza as palavras para gerar frases fluidas em português, um processo que não pode ser avaliado somente por métricas de classificação tradicionais (VASWANI et al., 2017; TOUVRON et al., 2023). Conforme apontam Papineni et al. (2002), a métrica captura tanto a precisão lexical quanto aspectos da fluência, ao penalizar hipóteses que se distanciam estruturalmente das referências humanas.

Para a validação do sistema proposto, o BLEU será calculado comparando as sentenças finais em português (após o refinamento linguístico realizado pelo LLM) com traduções de referência elaboradas por intérpretes de Libras para o mesmo conjunto de sinais de entrada (TOUVRON et al., 2023). Escores mais altos indicam que a integração entre NLP e LLM é capaz de gerar saídas linguisticamente próximas ao que um humano produziria a partir dos mesmos sinais (TOUVRON et al., 2023).

Nesse sentido, o BLEU complementa as métricas de reconhecimento gestual ao avaliar especificamente a qualidade da camada linguística do sistema, fechando o ciclo de avaliação do pipeline completo de tradução.

2.3.17 Latência e Tempo de Resposta

A latência corresponde ao tempo decorrido entre a captura do sinal pelo sistema e a exibição da tradução ao usuário. Em aplicações de tradução em tempo real, esse fator é crítico, pois impacta diretamente a experiência de uso e a fluidez da comunicação.

Sistemas com alta latência podem gerar atrasos perceptíveis, comprometendo a interação entre os usuários. Por isso, é necessário otimizar todas as etapas do pipeline, desde a captura do vídeo até o processamento pelos modelos e a geração da saída textual.

De acordo com Molchanov et al. (2015), em sistemas de reconhecimento de gestos em tempo real, o desempenho está diretamente relacionado à eficiência computacional dos modelos e à capacidade de processar sequências de vídeo com baixa latência.

No presente trabalho, a latência será considerada como um dos principais critérios de

avaliação do sistema. A utilização de técnicas como processamento eficiente de frames, redução do tamanho dos dados (por meio de *landmarks*) e escolha de modelos com menor custo computacional contribui para minimizar o tempo de resposta.

Dessa forma, busca-se garantir que a tradução ocorra de forma rápida e contínua, aproximando-se de uma comunicação natural.

2.4 Trabalhos relacionados

2.4.1 Trabalho 1: Sign Language Translator System Using Computer Vision and LSTM Neural Networks

O estudo de [Wang, Jiang e Li \(2025\)](#) investigou o problema da dificuldade de comunicação entre pessoas surdas e ouvintes, causada pela falta de compreensão da língua de sinais, o que impacta diretamente o acesso a serviços e interações sociais, o mesmo problema abordado neste trabalho.

Para enfrentar essa questão, os autores desenvolveram um sistema de tradução de língua de sinais em tempo real, combinando técnicas de visão computacional, redes neurais convolucionais (CNN), redes recorrentes do tipo LSTM e processamento de linguagem natural. A metodologia incluiu a coleta e anotação de um dataset de gestos, seguido do treinamento de modelos capazes de reconhecer sinais e convertê-los em texto automaticamente.

Os resultados obtidos demonstraram uma precisão de 97% no reconhecimento dos gestos, indicando que a abordagem é eficaz para cenários controlados. Além disso, o sistema mostrou potencial para melhorar a acessibilidade e a inclusão social.

Entretanto, a solução apresenta limitações importantes, como a dependência de condições ambientais controladas (iluminação e fundo), a escassez de datasets amplos, e dificuldades em manter desempenho em tempo real. Também há restrições relacionadas à acessibilidade, especialmente em sistemas baseados na web que dependem de conexão com a internet.

Diferentemente desse trabalho, a presente pesquisa propõe uma abordagem mais integrada, ao não apenas reconhecer os sinais, mas também estruturá-los linguisticamente por meio de processamento de linguagem natural, buscando gerar frases coerentes em português, e não apenas transcrições diretas de sinais.

2.4.2 Trabalho 2: Interpretação de gestos de Libras usando K-Means e Random Forest

[Caiafa et al. \(2023\)](#) propuseram uma solução para o reconhecimento automático de sinais da Libras com foco em reduzir o custo computacional, mantendo uma boa acurácia.

O problema tratado também está relacionado à barreira de comunicação entre usuários e não usuários da língua de sinais, sendo, portanto, diretamente alinhado com esta pesquisa.

A abordagem adotada pelos autores difere das soluções baseadas exclusivamente em *deep learning*, pois utiliza o MediaPipe para extração de pontos-chave corporais, seguido de técnicas de agrupamento com K-Means e classificação utilizando algoritmos como KNN e Random Forest. Essa metodologia permite trabalhar com representações mais leves dos dados, reduzindo o processamento necessário.

Os experimentos foram realizados utilizando a *dataset* MINDS-Libras, resultando em uma acurácia de 94,72%, demonstrando que a solução é eficiente mesmo com menor complexidade computacional.

Apesar dos bons resultados, o trabalho apresenta limitações, principalmente no fato de que o sistema foca apenas na classificação de sinais isolados, sem tratar a construção de frases ou o contexto linguístico. Além disso, ainda enfrenta desafios comuns da área, como variações de iluminação, ângulo de câmera e aumento do vocabulário.

O presente trabalho avança em relação a essa proposta ao incorporar, além da etapa de reconhecimento, um módulo de processamento de linguagem natural, responsável por organizar os sinais identificados em frases estruturadas em português, ampliando o nível de interpretação da comunicação.

2.4.3 Trabalho 3: Detection and Interpretation of Indian Sign Language Using LSTM Networks

Vyavahare et al. (2023) abordaram o desenvolvimento de um sistema para reconhecimento e interpretação da língua de sinais indiana (ISL) em tempo real, com o objetivo de reduzir a lacuna comunicacional entre pessoas com deficiência auditiva e a sociedade, problema equivalente ao tratado neste TCC.

A solução proposta baseia-se no uso de técnicas de visão computacional para extração de características visuais, combinadas com redes neurais recorrentes do tipo LSTM, capazes de capturar dependências temporais em gestos dinâmicos. Os autores também criaram um dataset próprio, composto por vídeos anotados de usuários nativos de ISL.

Os resultados experimentais indicaram um desempenho elevado, com 96% de acurácia no treinamento e 87% no teste, evidenciando a capacidade do modelo em reconhecer padrões gestuais dinâmicos.

No entanto, o estudo apresenta algumas limitações relevantes. A principal delas é que o sistema está restrito ao reconhecimento de palavras isoladas, não sendo capaz de interpretar frases completas. Além disso, o desempenho pode ser afetado por fatores como variações de iluminação, ângulo de câmera e posicionamento das mãos.

Este trabalho se diferencia ao propor uma solução que vai além do reconhecimento de gestos individuais, incorporando uma camada de processamento de linguagem natural

para construção de frases, buscando uma tradução mais próxima da comunicação real entre Libras e língua portuguesa.

Tabela 3 – Comparação entre trabalhos relacionados

Critério	Trabalho 1	Trabalho 2	Trabalho 3	Este trabalho
Objetivo	Tradução de sinais em tempo real para texto.	Classificação de sinais de Libras com baixo custo computacional.	Reconhecimento e interpretação de sinais dinâmicos (ISL).	Tradução de Libras com estruturação gramatical de frases.
Tecnologia	CNN, LSTM e NLP básico.	MediaPipe, K-Means, KNN e Random Forest.	Visão Computacional (OpenCV) e LSTM.	Arquitetura híbrida CNN + LSTM e camada robusta de NLP.
Validação	Dataset próprio (webcam); Acurácia de 97%.	Base pública MINDS-Libras; Acurácia de 94,72%.	Dataset próprio (ISL); 96% treino e 87% teste.	Dataset de Libras, métricas de acurácia e avaliação sintática.
Limitação	Sensível à iluminação e dependência de conexão web.	Classificação restrita a sinais/palavras isoladas.	Não interpreta frases completas ou contexto linguístico.	Dependência de dataset abrangente para diversidade de sinais.

Autoria própria (2026).

3 Desenvolvimento

A Figura 13 apresenta uma visão geral da arquitetura proposta para o sistema de tradução automática de Libras para a língua portuguesa. O fluxo detalhado no diagrama inicia-se com a captura dos sinais por meio de uma câmera, que fornece ao sistema imagens estáticas ou sequências de vídeo contendo os gestos realizados pelo usuário.




Figura 13 – Diagrama de fluxo da solução proposta.

Autoria própria (2026).

A partir dessa entrada, os dados são encaminhados para diferentes módulos de processamento conforme sua natureza. Imagens estáticas são tratadas por uma Rede Neural

Convolutacional (CNN), responsável pela extração e análise de características espaciais, enquanto vídeos são processados por uma Rede de Memória de Longo Prazo (LSTM), capaz de modelar as dependências temporais presentes nos movimentos dos sinais.

Após o reconhecimento dos gestos, os resultados são encaminhados para um módulo de Processamento de Linguagem Natural (NLP), responsável pela interpretação linguística da sequência reconhecida. Por fim, um módulo de LLM realiza o refinamento sintático e semântico para produzir uma frase coerente em português, constituindo a saída final do sistema.

As próximas seções detalham cada componente dessa arquitetura, bem como as tecnologias empregadas, o fluxo de processamento adotado e as estratégias utilizadas para o treinamento e avaliação dos modelos.

3.1 Solução proposta

3.1.1 Visão geral da solução

A aplicação é composta por quatro módulos principais integrados em um *pipeline* de processamento sequencial: (i) o módulo de visão computacional, responsável pela captura simultânea dos *landmarks* manuais e das expressões faciais; (ii) os modelos de reconhecimento, CNN para sinais estáticos e LSTM para sinais dinâmicos, que classificam os gestos e as expressões capturadas; (iii) o módulo de processamento de linguagem natural, responsável pela conversão dos *tokens* reconhecidos em frases estruturadas em português; e (iv) o módulo LLM, que refina a saída produzida pelo NLP para garantir fluência e naturalidade na sentença final.

O processamento inicia-se com a captura contínua de frames pela câmera. Cada frame é analisado pelo módulo de visão computacional para verificar a presença das regiões de interesse. Quando uma mão é detectada, o *MediaPipe* realiza a extração dos *landmarks* das mãos e da face, gerando uma representação geométrica dos gestos e das expressões faciais do sinalizador.

Em seguida, o sistema determina o tipo de sinal a ser processado: sinais estáticos são encaminhados para a CNN, responsável pela classificação espacial das configurações de mão, enquanto sinais dinâmicos são processados pela LSTM, que modela as informações temporais contidas na sequência de movimentos.

Após a classificação, é realizada uma verificação de confiança da predição. Caso a confiança esteja abaixo do limiar estabelecido, o token reconhecido é descartado ou uma mensagem de alerta é exibida ao usuário. Caso contrário, o token é adicionado à fila de sinais reconhecidos.

Quando o sistema identifica o término da sentença, a sequência de tokens é enviada ao módulo de NLP, que executa a reordenação sintática, os ajustes de concordância e flexão e

a geração de uma frase estruturada em português.

Em seguida, essa sentença é encaminhada ao módulo de LLM, responsável por refinar aspectos sintáticos, semânticos e de fluência textual, produzindo uma saída mais natural e próxima da linguagem utilizada por falantes nativos.

Por fim, a frase resultante é apresentada ao usuário por meio da interface da aplicação, conforme ilustrado na Figura 14.




Figura 14 – Fluxograma de Execução do Pipeline.

Autoria própria (2026).

3.1.2 Domínio de Aplicação e Seleção do Vocabulário

O sistema adota uma estratégia de foco em domínio: em vez de buscar cobertura superficial de um léxico amplo e heterogêneo, o *pipeline* completo é desenvolvido e validado sobre um conjunto de sinais pertencentes a uma categoria temática específica. Essa abordagem é deliberada e tecnicamente justificada, garantindo que os modelos CNN e LSTM sejam treinados sobre dados semanticamente coerentes, que o módulo de NLP opere com um vocabulário bem mapeado e que o LLM possa refinar traduções com base em contexto definido, resultando em um sistema de alta qualidade dentro do seu escopo.

A seleção do domínio de aplicação é realizada com base em análise quantitativa e qualitativa dos três *datasets* disponíveis (MINDS-Libras, V-Librasil e Libras Brazilian Sign Language), priorizando a categoria que ofereça: (a) maior quantidade de amostras por sinal e diversidade de sinalizadores; (b) relevância social comprovada para contextos de inclusão, como saúde, atendimento ao público ou educação; e (c) representação equilibrada entre sinais estáticos e dinâmicos, de modo a exercitar plenamente ambas as arquiteturas de reconhecimento (CNN e LSTM). A definição final do domínio será documentada e justificada com dados quantitativos na etapa de desenvolvimento do TCC2.

3.1.3 Tamanho do Vocabulário e Tipos de Sinais Suportados

O sistema reconhece e traduz sinais pertencentes ao domínio temático selecionado, cobrindo tanto o componente manual quanto o componente não manual (expressões faciais) dos gestos. O vocabulário é dimensionado para garantir profundidade de cobertura dentro do domínio escolhido, com um número suficiente para compor enunciados completos e contextualmente significativos em cenários reais de uso.

Em termos de tipologia, o sistema suporta três categorias de entrada:

- Sinais manuais estáticos: Configurações de mão realizadas sem componente de movimento significativo, como letras do alfabeto manual e numerais. Processados pela CNN a partir dos *landmarks* extraídos pelo *MediaPipe Hands* em um único *frame*.
- Sinais manuais dinâmicos: Gestos que envolvem trajetória e movimento ao longo do tempo, categoria que abrange a maior parte do léxico cotidiano da Libras. Processados pela LSTM a partir de sequências temporais de *landmarks*.
- Expressões Não Manuais (ENM): Expressões faciais com função gramatical na Libras, como marcação de perguntas (sobrancelhas elevadas), negação facial e intensificação. Capturadas em tempo real pelo *MediaPipe Face Mesh* e classificadas em conjunto com os *landmarks* manuais, permitindo que o sistema distinga enunciados com o mesmo sinal manual mas significados distintos conforme a expressão que os acompanha.

3.1.4 Desafios do Sistema

O desenvolvimento do sistema envolve desafios técnicos inerentes à natureza contínua e visual da Libras, que motivam decisões arquiteturais específicas e orientam o planejamento das etapas de implementação e validação.

O primeiro desafio é a detecção dos limites temporais dos sinais, identificar, no fluxo contínuo de vídeo capturado pela câmera, o exato instante em que um sinal começa e termina. Diferentemente do reconhecimento de fala, em que pausas sonoras delimitam palavras, na Libras os sinais são realizados em movimento contínuo, sem separadores visuais explícitos entre eles. O sistema precisa, portanto, implementar um mecanismo de segmentação temporal capaz de distinguir o momento em que o sinalizador está ativamente produzindo um sinal daquele em que está em transição ou repouso, para que apenas sequências válidas sejam enviadas aos modelos de classificação.

O segundo desafio é a distinção entre sinais dinâmicos e estáticos no mesmo fluxo de entrada. Sinais estáticos, como configurações do alfabeto manual, são realizados com a mão relativamente imóvel, enquanto sinais dinâmicos envolvem trajetória e movimento intencional. Como ambos chegam ao sistema como sequências de *frames*, é necessário que o *pipeline* classifique automaticamente o tipo de sinal recebido antes de direcioná-lo ao modelo correto (CNN ou LSTM), evitando que micro-movimentos involuntários de manutenção de postura sejam interpretados como gestos dinâmicos.

O terceiro desafio é o tratamento de ruídos e interrupções naturais da captura. Durante o uso real, o sinalizador pode fazer pausas entre sinais, ajustar a posição das mãos, mexer no rosto ou simplesmente manter as mãos em repouso no campo da câmera. Esses comportamentos produzem sequências de *landmarks* que não correspondem a nenhum sinal válido, mas que o sistema poderia interpretar incorretamente como entrada. Além disso, oclusões parciais das mãos, variações bruscas de iluminação e perda momentânea de detecção pelo MediaPipe introduzem lacunas e inconsistências nos vetores de entrada que precisam ser tratadas antes da classificação, por meio de técnicas como interpolação de *frames* ausentes, janelas deslizantes com limiar de confiança e descarte de sequências com detecção abaixo do mínimo aceitável.

3.1.5 Limitações do Sistema

As limitações a seguir definem o escopo desta pesquisa e orientam o planejamento de trabalhos futuros. Elas não representam restrições ao mérito da solução proposta, mas delimitam com precisão o contexto em que os resultados devem ser interpretados.

1. Cobertura restrita ao domínio selecionado: O sistema realiza tradução de alta qualidade dentro do domínio temático escolhido. Sinais fora desse escopo não serão reconhecidos, o que é uma consequência esperada e planejada da estratégia de foco

em domínio adotada. A extensão do vocabulário a outros domínios é um trabalho futuro natural.

2. Sinais classificadores e polissêmicos complexos: Sinais cujo significado depende criticamente de contexto espacial tridimensional complexo, como classificadores que referenciam objetos posicionados no espaço de sinalização, estão fora do escopo desta versão, dado que o *pipeline* atual não modela explicitamente o espaço de referência da Libras.
3. Dependência de condições mínimas de captura: Embora o uso de *landmarks* pelo MediaPipe reduza significativamente a sensibilidade a variações de iluminação e fundo, situações de oclusão severa das mãos ou iluminação extremamente baixa podem comprometer a detecção. Câmeras com resolução mínima adequada são requisito de hardware do sistema.
4. Latência do módulo LLM em hardware limitado: Em dispositivos com recursos computacionais mais restritos, a chamada ao LLM pode introduzir atrasos perceptíveis. A validação de latência incluirá testes em diferentes configurações de hardware para mapear os requisitos mínimos do sistema.

3.1.6 Arquitetura

A arquitetura do sistema é organizada de forma modular, dividida em quatro camadas principais de processamento que interagem sequencialmente. Conforme ilustrado no diagrama estrutural da Figura 15, o fluxo de dados percorre caminhos bem definidos para garantir a precisão do reconhecimento e a fluência da tradução final:




Figura 15 – Fluxo de Processamento da Arquitetura Híbrida.

Autoria própria (2026).

1. Camada de Aquisição e Visão (Captura): Responsável por receber o fluxo de vídeo e executar simultaneamente dois processos de extração de *landmarks*: (a) o *MediaPipe Hands*, que mapeia 21 pontos-chave das articulações de cada mão, fornecendo coordenadas tridimensionais (x, y, z); e (b) o *MediaPipe Face Mesh*, que rastreia pontos-chave do rosto, incluindo sobrancelhas, olhos, bochecha e boca, capturando as Expressões Não Manuais (ENM) que exercem funções gramaticais na Libras.

2. Camada de Inteligência (Processamento Híbrido): O núcleo do sistema de reconhecimento. As Redes Neurais Convolucionais (CNN) processam a geometria espacial combinada dos *landmarks* manuais e faciais para classificar sinais estáticos, como as configurações do alfabeto manual e expressões de negação ou interrogação. As Redes de Memória de Longo Prazo (LSTM) interpretam a continuidade temporal dessas representações para o reconhecimento de sinais dinâmicos, cujo significado depende da trajetória do movimento ao longo do tempo.
3. Camada de Interpretação Linguística (NLP): Módulo implementado com a biblioteca spaCy que recebe os *tokens* reconhecidos, incluindo informações semânticas derivadas das ENM, e aplica tokenização, etiquetagem morfosintática, análise de dependência sintática e regras de concordância para gerar frases gramaticalmente estruturadas em língua portuguesa.
4. Camada de Refinamento (LLM): Módulo de pós-processamento que recebe a sentença intermediária produzida pelo NLP e aplica um Modelo de Linguagem de Grande Escala para otimizar a naturalidade e a fluência do texto final, corrigindo ambiguidades e inserindo elementos contextuais que regras determinísticas não capturam.

3.1.7 Tecnologias e ferramentas

As escolhas tecnológicas foram feitas visando o alto desempenho em processamento de tensores e visão computacional:


- Linguagem de Programação: Python, devido à sua maturidade e vasta biblioteca para IA.
- Frameworks de Inteligência Artificial: TensorFlow ou Keras para o desenvolvimento das arquiteturas CNN e LSTM.
- Visão Computacional: *MediaPipe Hands* para a extração de *landmarks* das mãos, *MediaPipe Face Mesh* para os *landmarks* das expressões faciais.
- Dataset: Minds-Libras, Libras Brazilian Sign Language e V-BrasilLL escolhidos pela diversidade de sinais e qualidade das anotações.
- Processamento de Texto: Biblioteca spaCy para as tarefas de NLP e adequação gramatical.
- Modelo de Linguagem de Grande Escala: Llama ou Gemma, utilizados na camada de refinamento linguístico para garantir fluência e naturalidade na sentença final gerada em português.

3.1.8 Funcionalidades principais

Para atingir os objetivos propostos, o sistema disponibilizará as seguintes funcionalidades:

- Captura de Sinais em Tempo Real: Processamento de vídeo via câmera com baixa latência.
- Reconhecimento de Sinais Estáticos e Dinâmicos: Capacidade de traduzir desde o alfabeto manual, como o da Figura 16, até gestos complexos em movimento.

Figura 16 – Alfabeto de Libras.



Fonte: Nascimento (2018).

- Tradução Sintática: Reorganização de sentenças da estrutura Libras para a estrutura SVO do português.
- Saída: Exibição da tradução em texto na tela.

3.1.9 Metodologia de desenvolvimento

O projeto adotará a metodologia ágil Scrum, organizada em ciclos de desenvolvimento (Sprints). A escolha justifica-se pela natureza experimental de modelos de IA, permitindo testes contínuos e ajustes refinados nos hiperparâmetros das redes neurais a cada entrega parcial (prototipação).

3.1.10 Critérios de validação

O sucesso da solução será medido através de métricas quantitativas e qualitativas:

- Acurácia e Precisão: Medição da taxa de acerto do modelo na classificação dos sinais utilizando uma matriz de confusão.

- Métrica BLEU (*Bilingual Evaluation Understudy*): Utilizada para avaliar a qualidade da tradução gerada pelo módulo de NLP em comparação com traduções humanas.
- Tempo de Resposta: Testes de latência para garantir que a tradução ocorra em tempo de execução.
- Validação com Usuários Reais: Sessões supervisionadas com membros da comunidade surda e/ou intérpretes de Libras para avaliação qualitativa das traduções e da usabilidade do sistema em condições reais de uso.

3.2 Cronograma de trabalho

O cronograma a seguir apresenta, no formato de diagrama de Gantt, as atividades previstas para o desenvolvimento do TCC2, distribuídas ao longo das semanas do semestre.




Figura 17 – Cronograma de atividades – Diagrama de Gantt

Autoria própria (2026).

Referências

- ALMEIDA, R. C. de. *Uso de Redes Neurais Long Short-Term Memory como Estratégia de Algorithmic Trading*. Dissertação (Projeto de Graduação (Engenharia Elétrica)) — Universidade Federal do Espírito Santo, Vitória, 2019. 24
- BAYER, J. et al. Evolving memory cell structures for sequence learning. Springer, Manno-Lugano, p. 755 – 764, 2009. 23
- BIRD, S.; KLEIN, E.; LOPER, E. *Natural Language Processing with Python*. [S.l.]: O'Reilly Media, 2009. 27, 28
- BRITO, L. F. *Por uma Gramática de Língua de Sinais*. Rio de Janeiro: Tempo Brasileiro, 1995. 10, 19
- BROWN, T. B. et al. Language models are few-shot learners. *Advances in Neural Information Processing Systems (NeurIPS)*, v. 33, p. 1877–1901, 2020. 6, 29
- CAIAFA, E. G. de A. et al. Interpretação de gestos de libras usando k-means e random forest. *XLI Simpósio Brasileiro De Telecomunicações E Processamento De Sinais (SBrT2023)*, 2023. 32
- CHAWLA, N. V. et al. SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, v. 16, p. 321–357, 2002. 17
- CHEN, M. *O que é Machine Learning?* 2024. Acesso em: 03 jun. 2026. Disponível em: <<https://www.oracle.com/br/artificial-intelligence/machine-learning/what-is-machine-learning/>>. 14
- Cole Stryker and Jim Holdsworth. *O que é processamento de linguagem natural (NLP)?* 2024. Acesso em: 19 abr. 2026. Disponível em: <<https://www.ibm.com/br-pt/think/topics/natural-language-processing>>. 27
- Computer Weekly. *Definição: Aprendizado profundo (deep learning)*. 2026. Acessado em: 17 mai. 2026. Disponível em: <<https://www.computerweekly.com/br/definicoes/Aprendizado-profundo-deep-learning>>. 21
- CONTARINI, G. *Redes Neurais LSTM e Modelo GARCH: Uma Abordagem Conjunta para Previsão de Retornos*. Dissertação (Monografia (Bacharelado em Economia)) — Universidade Federal do Rio de Janeiro, Rio de Janeiro, 2020. 24
- Dave Bergmann. *O que é visão computacional?* 2025. Acesso em: 15 abr. 2026. Disponível em: <<https://www.ibm.com/br-pt/think/topics/computer-vision>>. 17
- Dave Bergmann. *O que é deep learning?* 2026. Acesso em: 19 abr. 2026. Disponível em: <<https://www.ibm.com/br-pt/think/topics/deep-learning>>. 20
- FACELI, K. et al. *Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina*. 2. ed. [S.l.]: LTC, 2021. 14

- FELIPE, T. A. *O discurso verbo-visual na língua brasileira de sinais - Libras*. 2013. Acesso em: 07 maio 2025. Disponível em: <<https://www.scielo.br/j/bak/a/MJ378DGggYhnmTfCFzh6VRy/?lang=pt>>. 11
- FLECK, L. et al. Redes neurais artificiais: Princípios básicos. *Revista Eletrônica Científica Inovação e Tecnologia*, v. 7, n. 15, p. 47–57, 2016. 21, 22, 23
- FURTADO, M. I. V. *Redes Neurais Artificiais: Uma Abordagem Para Sala de Aula*. 1. ed. Ponta Grossa, PR: Atena Editora, 2019. 22, 23
- Gemma Team et al. Gemma: Open models based on gemini research and technology. *arXiv preprint arXiv:2403.08295*, 2024. 29
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Aprendizado Profundo*. Cambridge: MIT Press, 2016. 15, 16, 17, 21, 22, 29, 30
- GÉRON, A. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. 3. ed. [S.l.]: O'Reilly Media, 2022. 14
- HOCHREITER, S.; SCHMIDHUBER, J. Long short-term memory. *MIT Press*, v. 9, n. 8, p. 1735 – 1780, 1997. 5, 23
- HONNIBAL, M. et al. *spaCy: Industrial-strength Natural Language Processing in Python*. 2020. Software. Disponível em: <<https://spacy.io>>. Acesso em: 30 abr. 2026. 26, 27, 28
- IBGE. *Pesquisa Nacional de Saúde*. 2019. Acesso em: 16 abr. 2026. Disponível em: <<https://sidra.ibge.gov.br/tabela/8223>>. 6
- IBM. *What is Machine Learning?* 2026. Disponível em: <https://www.ibm.com/topics/machine-learning>. Acesso em: 2026. 14
- IONOS Digital Guide. *Convolutional Neural Network: como funcionam as redes neurais convolucionais*. 2026. Acessado em: 17 mai. 2026. Disponível em: <<https://www.ionos.com/pt-br/digitalguide/sites-de-internet/desenvolvimento-web/convolutional-neural-network/>>. 23
- JURAFSKY, D.; MARTIN, J. H. *Speech and Language Processing*. 3. ed. [S.l.]: Prentice Hall, 2023. Rascunho online. Disponível em: <<https://web.stanford.edu/~jurafsky/slp3/>>. 6, 12, 26, 27
- JÚNIOR, R. F. P. *Utilização de inteligência artificial na tradução de língua gestual para língua verbal*. Dissertação (Dissertação (Mestrado em Engenharia Elétrica e de Computação)) — Universidade Federal do Ceará, Sobral, 2019. 25
- KHALEEL, A. H.; ABBAS, T. H.; IBRAHIM, A.-W. S. Best low-cost methods for real-time detection of the eye and gaze tracking. *i-com*, v. 23, n. 1, p. 79–94, 2024. Disponível em: <https://www.researchgate.net/figure/Media-pipe-face-mesh-solution-map_fig3_377232980>. Acesso em: 26 mai. 2026. 20
- KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. ImageNet classification with deep convolutional neural networks. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2012. v. 25. 21

- LECUN, Y. et al. Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, v. 86, n. 11, p. 2278–2324, 1998. 5, 21, 22
- LOPEZ, M. M.; KALITA, J. Deep learning applied to nlp. *arXiv preprint arXiv:1703.03091*, 2017. 11, 27, 28
- LUGARESI, C. et al. Mediapipe: A framework for building perception pipelines. *arXiv preprint arXiv:1906.08172*, 2019. 5, 18, 19, 20
- MILANO, D. de; HONORATO, L. B. *Uso de Redes Neurais Long Short-Term Memory como Estratégia de Algorithmic Trading*. Dissertação (Artigo (Faculdade de Tecnologia)) — Universidade Estadual de Campinas, Limeira, 2014. 17
- MITCHELL, T. M. *Machine Learning*. [S.l.]: McGraw-Hill, 1997. 14
- MOLCHANOV, P. et al. Hand gesture recognition with 3d convolutional neural networks. *IEEE*, p. 1–7, 2015. 31
- MONTEIRO, C. H. de A. et al. Um sistema de baixo custo para reconhecimento de gestos em libras utilizando visão computacional. *XXXIV Simpósio Brasileiro De Telecomunicações - SBrT2016*, 2016. 25
- NASCIMENTO, T. *Linguagem de sinais: aprenda algumas palavras e frases em libras*. 2018. Acesso em: 07 maio 2025. Disponível em: <<https://segredosdomundo.r7.com/linguagem-de-sinais-aprenda-algumas-palavras-e-frases-em-libras/>>. 43
- NEVES, L. A. P.; NETO, H. V.; GONZAGA, A. *Avanços em visão computacional*. 1. ed. Paraná: Omnipax, 2012. 17
- OLIZAROSKI, I. M. H.; MOLIN, B. H. D. Diferenças gramaticais entre a libras e a língua portuguesa com Ênfase à conjugação e transitividade verbal. *Revista Advérbio*, v. 18, n. 35, 2024. 5
- Oracle. *O que é deep learning?* 2022. Acesso em: 19 abr. 2026. Disponível em: <<https://www.oracle.com/br/artificial-intelligence/machine-learning/what-is-deep-learning/>>. 20
- OSÓRIO, J. R. de Bittencourt Menezes e F. S. O uso de redes neurais artificiais na detecção de pele em imagens digitais visando o reconhecimento de gestos. *Seminário de Computação - SEMINCO*, 2002. 25
- PAPINENI, K. et al. BLEU: a method for automatic evaluation of machine translation. In: *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*. [S.l.: s.n.], 2002. p. 311–318. 6, 31
- PAS, B. T. *Brazilian Sign Language Alphabet Dataset*. 2020. Mendeley Data. Disponível em: <<https://data.mendeley.com/datasets/k4gs3bmx5k>>. Acesso em: 30 abr. 2026. 6, 15
- PINHO, R. R.; TAVARES, J. M. R. S.; CORREIA, M. F. P. V. *Introdução à Análise de Movimento usando Visão Computacional*. Dissertação (Relatório Interno (Engenharia e Gestão Industrial)) — Universidade do Porto, Porto, 2004. 18
- QUADROS, R. M. de; KARNOPP, L. B. *Língua de Sinais: Estudos Linguísticos*. 1. ed. Porto Alegre: ArtMed, 2004. 5, 10, 11, 12

- REPÚBLICA, P. da. *Decreto nº5.626, de 22 de dezembro de 2005. Regulamenta a Lei nº10.436, de 24 de abril de 2005, que dispõe sobre a Língua Brasileira de Sinais (Libras), e o art. 18 da Lei nº10.098, de 19 de dezembro de 2000*. Disponível em: <>. Acesso em: 27 abr. 2026. 10
- REZENDE, T. M. *Reconhecimento automático de sinais da Libras: desenvolvimento da base de dados MINDS-Libras e modelos de redes convolucionais*. Tese (Doutorado) — Universidade Federal de Minas Gerais, Belo Horizonte, 2021. 6, 15
- RODRIGUES, A. J. *V-LIBRASIL: uma base de dados com sinais na língua brasileira de sinais (Libras)*. Tese (Doutorado) — Universidade Federal de Pernambuco, Recife, 2021. 6, 15
- RUSSELL, S.; NORVIG, P. *Artificial Intelligence: A Modern Approach*. 4. ed. [S.l.]: Pearson, 2021. 13, 14
- SCHMIDHUBER, J. Deep learning in neural networks: An overview. *Neural Networks*, v. 61, p. 85 – 117, 2014. 15, 21, 24
- SILVA, S. R. *Reconhecimento de gestos customizados da mão em tempo real usando aprendizado de métricas e grafos de ação*. Dissertação (Dissertação (Mestrado em Instituto de Matemática)) — Universidade Federal de Alagoas, Maceió, 2017. 15, 25
- SZELISKI, R. *Computer Vision: Algorithms and Applications*. 2. ed. Ponta Grossa, PR: Springer, 2010. 16
- TensorFlow. *Hand-pose-detection: MediaPipe Hands landmarks description*. 2021. Repositório no GitHub. Disponível em: <<https://github.com/tensorflow/tfjs-models/blob/master/hand-pose-detection/README.md>>. Acesso em: 26 mai. 2026. 19
- TOUVRON, H. et al. Llama 2: Open foundation and fine-tuned chat models. *arXiv preprint arXiv:2307.09288*, 2023. 29, 31
- VASWANI, A. et al. Attention is all you need. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2017. v. 30. 29, 31
- VYAVAHARE, P. et al. Detection and interpretation of indian sign language using lstm networks. *Journal of Intelligent Systems and Control*, 2023. 33
- WANG, Y.; JIANG, W.; LI, D. Sign language translator system using computer vision and lstm neural networks. *International Journal of Information Technologies and Systems Approach*, v. 18, 2025. 32
- ZHANG, F. et al. Mediapipe hands: On-device real-time hand tracking. In: *arXiv preprint arXiv:2006.10214*. [S.l.: s.n.], 2020. 5, 18, 19